

分类号: TM411

密 级: 公开

UDC:           

单位代码: 10142

沈阳工业大学  
**硕士学位论文**

大型变压器的智能诊断与故障预测



学 号: 201920013  
作 者: 冯百卿  
学 位 类 别: 工程硕士  
领 域: 机 械  
论 文 类 型: 研究论文

**2022 年 5 月 30 日**

# 沈阳工业大学硕士学位论文

## 大型变压器的智能诊断与故障预测

Intelligent Diagnosis and Fault Prediction of Large Transformer

作 者: 冯百卿 单位: 机械工程学院

指 导 教 师: 孟新宇 教授 单位: 沈阳工业大学

协助指导教师: 陈长征 教授 单位: 沈阳工业大学

论文答辩日期: **2022 年 5 月 28 日**

学位授予单位: **沈 阳 工 业 大 学**

## 独 创 性 说 明

本人郑重声明：所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写的研究成果，也不包含为获得沈阳工业大学或其他教育机构的学位或证书所使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中做了明确的说明并表示了谢意。

签名：冯有卿 日期：2022.05.30

## 关于学位论文使用授权的说明

本学位论文作者和指导教师完全了解沈阳工业大学有关保留、使用学位论文的规定，即：学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅；本人授权沈阳工业大学可以将学位论文的全部或部分内容编入有关数据库进行检索、交流，可以采用影印、缩印或其他复制手段保存论文和汇编本学位论文。

（保密的论文在解密后应遵循此规定）

签名：冯有卿 导师签名：孟新宇 日期：2022.05.30

## 摘要

电力变压器作为电力系统中必不可少的基础设备，它的平稳长久运行，关系到整个电力系统的正常运转。因此，针对变压器的智能诊断与故障预测就显得非常必要。油中溶解气体含量作为变压器运行状态评估的重要指标，被广泛应用到变压器的故障诊断与预测领域。本文研究了如何通过变压器油中溶解气体含量来实现变压器的故障分类诊断以及对未来变压器可能发生故障的精准预测。

本文在深入研究大型油浸式变压器的结构特点、产气原理、故障类型以及产气与故障之间的内部关联的基础上，结合目前国内外主流的变压器故障诊断方法以及实际所测数据量的大小，提出了一种改进麻雀算法优化支持向量机(Support vector machine, SVM)的变压器故障诊断模型。首先该方法针对传统故障诊断方法诊断准确率低，采用麻雀算法(The sparrow algorithm, SSA)来优化支持向量机的参数，在参数的优化过程中进行了改进，引进反向学习策略来提高麻雀算法初始种群的质量，同时针对麻雀位置易陷入到局部最优的缺点引进了萤火虫扰动策略，提高了算法的全局寻优能力；经过仿真测试，证明了改进后算法具有更好的优化性能；然后构建了最优变压器故障诊断模型。依据相关导则，重构了 14 组特征输入，确定了变压器的 5 种故障类型；按照本文提出的故障诊断方法进行实例分析，结果显示本文提出的诊断模型精度更高、效果较好，更适合变压器故障诊断领域。

以油中溶解特征气体含量的历史变化特征为基础，提出了一种预测未来特征气体含量变化的模型，该模型主要以极限学习机(Extreme learning machine, ELM)网络为主体，考虑到该模型连接权重和偏置难以选择的缺点，采用改进的麻雀算法进行优选与提升。依据相关的导则确定以变压器溶解的五种特征气体含量作为输入，按照本文提出的预测模型进行实验，实验结果显示预测效果好、精度高。在此基础上，构建了改进麻雀算法优化支持向量机结合提升极限学习机的变压器故障预测模型；经过 200 组实际数据的实验测试，证明了该故障预测模型具有优秀的性能，可以为变压器的状态检修提供有价值的参考。

**关键词：**电力变压器，故障诊断，麻雀算法，极限学习机，故障预测

## Abstract

Power transformer is an essential basic equipment in power system. Its stable and long-term operation is related to the normal operation of the whole power system. Therefore, it is very necessary for transformer intelligent inspection and maintenance and fault prediction. Dissolved gas content in oil is an important index to measure the operation state of transformer. It is widely used to diagnose and predict transformer faults. This paper studies the classification and diagnosis of transformer faults through the dissolved gas content in transformer oil, so as to realize the accurate prediction of transformer faults in the future.

Based on the in-depth study of the structural characteristics, gas production principle, fault types and the internal relationship between gas production and fault of oil immersed transformer, on the basis of combining with the mainstream of transformer fault diagnosis methods at home and abroad as well as the size of the actual measured data, this paper proposes a sparrow algorithm optimization of transformer fault diagnosis model of support vector machine (SVM). At first the method for fault diagnosis method of traditional diagnosis accuracy rate is low, the sparrow algorithm is used to optimize the parameters of support vector machine (SVM), in the process of parameter optimization is improved, the introduction of reverse learning strategies to improve the quality of the sparrow optimization algorithm of the initial population, at the same time for the sparrow position easily plunged into local optimal faults introduced a firefly perturbation strategy, Simulation results show that the improved algorithm has better optimization performance. The optimal transformer fault diagnosis model is established. Then the optimal transformer fault diagnosis model is constructed. According to relevant guidelines, 14 groups of characteristic inputs are reconstructed and 5 fault types of transformers are determined. The results show that the diagnosis model proposed in this paper has higher accuracy and better effect, and is more suitable for the field of transformer fault diagnosis.

According to the historical change characteristics of dissolved characteristic gas content in oil, a model for predicting the change of characteristic gas content in the future is proposed. The model mainly takes the extreme learning machine (ELM) network as the main body. Aiming at the connection weight and difficult selection of the model, the sparrow algorithm is

selected and improved. According to relevant guidelines, the content of five characteristic gases dissolved in the transformer is determined as input. According to the prediction model proposed in this paper, the experimental results show that the prediction effect is very good. Finally, a transformer fault prediction model based on improved sparrow algorithm optimized support vector machine and lifting limit learning machine is constructed; Through the experimental test of 200 groups of actual data, it is proved that the fault prediction model has excellent performance and can provide a valuable reference for transformer condition based maintenance.

**Key Words:** Power transformer, Fault diagnosis, Sparrow algorithm, Extreme learning machine, Failure prediction

# 目录

摘要.....	1
Abstract .....	II
第 1 章 绪论.....	1
1.1 课题研究背景及意义.....	1
1.2 国内外发展现状.....	3
1.2.1 变压器智能诊断发展现状.....	3
1.2.2 变压器故障预测发展现状.....	6
1.2.3 本文的主要研究内容.....	7
第 2 章 变压器故障产生机理和特征分析.....	9
2.1 变压器的结构和故障机理 .....	9
2.1.1 变压器基本结构与故障分类.....	9
2.1.2 变压器故障产生机理.....	10
2.2 变压器故障的特征分析 .....	12
2.2.1 故障气体产生来源.....	12
2.2.2 变压器内部气体含量标准.....	14
2.3 变压器故障类型与特征气体的关联 .....	15
2.4 其他特征与变压器故障的关联 .....	16
2.5 本章小结 .....	19
第 3 章 基于 FA-ISSA-SVM 的变压器故障诊断.....	20
3.1 变压器故障诊断方法 .....	20
3.2 智能优化算法 .....	24
3.2.1 麻雀搜索优化算法.....	24
3.2.2 算法的基本流程.....	26
3.3 麻雀搜索算法的改进 .....	26
3.3.1 反向学习策略.....	27
3.3.2 萤火虫扰动策略.....	27
3.4 改进算法的仿真测试 .....	28
3.5 基于 FA-ISSA-SVM 的变压器故障诊断 .....	30

3.5.1 模型输入输出的确定 .....	30
3.5.2 特征数据的预处理 .....	31
3.5.3 输出特征状态编码 .....	31
3.5.4 故障诊断模型的建立 .....	32
3.6 变压器故障诊断的实例分析 .....	32
3.6.1 样本数据收集与处理 .....	32
3.6.2 变压器的故障诊断 .....	33
3.7 本章小结 .....	38
<b>第4章 基于提升极限学习机的变压器故障预测 .....</b>	<b>39</b>
4.1 变压器故障预测方法 .....	39
4.2 变压器溶解气体含量预测模型的构建 .....	42
4.2.1 特征量的选取与处理 .....	42
4.2.2 变压器油中溶解气体含量预测模型 .....	43
4.3 变压器油中气体含量预测实例分析 .....	44
4.3.1 样本收集与处理 .....	44
4.3.2 变压器溶解气体含量预测 .....	45
4.4 变压器的故障预测 .....	49
4.4.1 实例分析 .....	50
4.5 本章小结 .....	53
<b>第5章 结论与展望 .....</b>	<b>54</b>
5.1 结论 .....	54
5.2 展望 .....	55
<b>参考文献 .....</b>	<b>56</b>
<b>在学研究成果 .....</b>	<b>60</b>
<b>致谢 .....</b>	<b>61</b>



# 第 1 章 绪论

## 1.1 课题研究背景及意义

近年来随着我国经济社会的快速发展，居民用电的需求也快速增加。电力系统作为国家至关重要的运行系统，它的安全稳定一定程度上决定着国家的经济与生产的快速发展。变压器作为电力行业中常见的基础设施，存在于生活中的每一个地方，无论是生活用电还是工业用电都离不开变压器的工作，因此变压器的稳定运行关系着社会经济的快速发展；如图 1.1 所示为换流站内部大型变压器。改革开放以来我们国家的电力网设施数量与日俱增，保证电力系统正常运转成为了每一个电力企业必不可少的一项工作。如果发生电力设备故障不仅会使得整个电力系统崩溃，而且还会影响到人民、企业、社会的经济，给社会带来不可估量的损失，给国家带了难以弥补形象损失<sup>[1-3]</sup>。



图 1.1 换流站大型变压器

Fig. 1.1 Large transformer in converter station

近些年来由于电力设备的损坏发生大面积停电的事故时有发生，2003 年 8 月 14 日，美国东北部、中西部和加拿大南部发生了大面积的停电事故。这次停电涉及到了整个美国东部的电网，据不完全统计至少 21 家电厂被迫停运，此次停电持续了大约 29 个小时，损失了负荷接近 61800MW，直接影响到了大约 5000 万居民的正常生活，造成了数以亿计的经济损失。根据事后公布的调查结果显示，最根本的原因还是电力设备没有得到定期的检修造成的机械故障；同年的 8 月 28 日和 9 月 23 日欧洲的英国伦敦和瑞典也发生了重大的停电事故，波及的范围也是相当的广泛，造成的经济损失更是巨大。无独有偶 2005 年 5 月 23 日晚 19: 57 分莫斯科地区发生了大面积的停电事故，涉及到了 25 座城市，共使得 321 家变电站脱离电网，直接造成的负荷损失更是巨大，

高达 3539.5MW，此次事故波及范围甚广，直接受到影响的居民就高达 400 多万，直接造成的经济损失更是高达 15-20 亿美元。事后的调查结果显示是由于事故发生的前一天运行了 40 年的变电站电流互感器发生爆炸引起的。由此可以看出对于定期对变电设备的维护是非常有必要的<sup>[4-7]</sup>。

目前对于变电设备的维护，检修部门都是通过对电器的收集到的数据进行分析来进行的定期维护。如图 1.2 所示为工人现场检修，从图中我们可以看出检修人员需要爬到变压器上面进行检查，这非常的危险，同时效率也很低。这么做虽然可以降低设备发生事故的的概率，但是由于我们国家人口众多，电力设备的数量数不胜数，各个地方的环境条件也不尽相同，因此定期维护遵循一定周期而不考虑设备的实际运行状况，显然是具有很大的弊端<sup>[8]</sup>。同时由于人工检测的准确率并没有那么高，造成的检修过度、检修不完全等事故频繁的发生，这样不仅没有降低故障发生概率，反而增加了劳动和经济成本。近些年来随着在线检测技术的发展，状态检测逐渐被应用于变压器的检修之中，状态检修具有很强的针对性。据调查显示精准高效的诊断技术对于减少变压器的故障发生率具有很好的帮助，也能够减少维护所需费用。因此，如何更好地利用先进的技术对变压器进行状态维修，成为现在的主流的研究热点。



图 1.2 变压器检修现场

Fig. 1.2 Transformer maintenance site

传统的油中溶解气体分析法(DGA)作为变压器故障诊断的首要方法，广泛的应用于我国电力系统中的变压器的故障分析中。通过以往的分析可以发现，变压器的不同故障会导致绝缘油中的不同特征气体的含量发生变化，因此通过此联系来对变压器进行故障分析无疑是最实用、最有效的方法。基于此，众多专家学者进一步的提出了针对变压器故障识别的方法，例如：IEC 三比值法、四比值法、无编码比值法等<sup>[9-10]</sup>。

但是随着智能计算机的崛起，社会上各行各业都针对计算机网络进行了有针对性

的升级。采用智能算法进行智能诊断与检测已逐步深入到变压器的故障诊断与预测领域。因此如何利用智能算法结合变压器传统的诊断方法进行快速、精确的智能诊断和通过对 DGA 方法的灵活运用来对变压器未来可能发生故障的预测就显得尤为重要。本文在详细分析国内外现有的研究成果的基础上,对变压器的智能诊断和故障预测开展了深入的研究,通过对主流的智能算法的深入分析,选择最适合变压器智能诊断与预测的模型方法,并且针对诊断和预测算法存在的缺陷进行优化与改进,进一步提高变压器的诊断和预测的准确率。本文的研究成果拥有很高的工程实践性,有助于电力系统维护人员对电力设备运行状态的精准预测,同时也为电力系统的安全可靠运行、定期维护提供了新方法、新技术。

## 1.2 国内外发展现状

变压器作为电力系统的“命脉”,承担着无可替代的工作,它的稳定运行,是整个电力系统平稳运转的重要前提。一旦发生故障,不仅会给社会居民带来巨大影响,同时也会影响国家的发展和社会经济的提高。由此可以看出如何快速的发现并且解决变压器的故障以及如何精准的预测变压器的故障,在电力系统发展行业中就显得尤为重要。

### 1.2.1 变压器智能诊断发展现状

目前主流的针对变压器故障诊断的方法,主要是通过 DGA 气体分析方法结合智能算法进行诊断。DGA 气体分析法作为传统的分析方法,具有检测方便不需要停机,不受变压器内部磁场干扰等优点,早已成为变压器的故障诊断与故障预测领域最重要的方法<sup>[11]</sup>。

目前国内外学者针对变压器的智能诊断主要集中在对油中溶解气体分析法(DGA)的应用,其中传统诊断方法有三比值法、无编码比值法、四比值法等。随着诊断技术的不断进步,近些年来越来越多的新兴算法被应用到变压器的故障诊断领域,其中主要以神经网络、模糊理论、专家系统、支持向量机为主,这不仅弥补了传统诊断方法诊断速度慢,诊断精度低的缺点,同时也加快了变压器定期维护的发展,节省了定期维护所需的经费。

#### (1) 基于油中溶解气体含量分析法

油中溶解气体含量分析法是 Halstead 于 1973 年第一次提出,一经提出便得到了国内外电力维护领域的专家学者的热力追捧<sup>[12]</sup>。DGA 分析法深入挖掘了变压器内部因不同故障导致的特征气体含量不变化之间的关系。1978 年国际电工委员会将这种特征之间的联系采用编码的形式表现出来,如表 1.1 所示,建立了经典的 IEC 三比值法,将

变压器的故障诊断方法推上更高层的台阶；随着深入研究发现 IEC 三比值法提供的编码不能编码变压器的所有故障，对于 DGA 数据并没有完全进行编码，这就对于变压器的故障诊断准确率有很大的影响，因此为了解决这一问题日本的电气协同研究会提出了电协研法，我国湖北电力研究所在此基础上提出了改良的电协研法，进一步的提高了变压器故障编码的完整性<sup>[13-15]</sup>。

表 1.1 IEC 三比值法编码原则  
Tab. 1.1 Coding principles of IEC three ratio method

气体比值范围	不同比值范围的编码		
	$C_2H_2/C_2H_4$	$CH_4/CH_2$	$C_2H_4/C_2H_6$
<0.1	0	1	0
0.1-1	1	0	0
1-3	1	2	1
>3	2	2	2

### (2) 基于模糊理论的故障诊断方法

变压器故障种类繁多，故障种类和故障激励之间仍然存在着很多的模糊性和随机性，如果单纯的应用传统的数学理论方法进行诊断，必然会降低其准确率，基于此模糊理论成为了解决这一问题的有效手段。模糊理论可以轻松的处理不确定关系，解决各类故障与其产生机理之间模糊性的问题，因此国内外众多学者将其引入到变压器的故障诊断领域内，并取得了一定的效果<sup>[16]</sup>。

刘凯等学者针对通过利用高斯核函数将测量的故障数据进行映射，映射到希尔伯特空间之中，再通过主成分分析的方法提取出最优的故障特征参量，将其进行最大的隶属度划分得出相应的故障类型<sup>[17]</sup>；Duraisamy V 分别利用三角函数、高斯隶属度函数对模糊系统进行了仿真测试，通过仿真测试发现模糊系统在变压器故障诊断领域具有很好的效果<sup>[18]</sup>；美国学者 Nitu M C，通过将呋喃衍生物浓度分析方法与传统的油中溶解气体分析法相结合，应用模糊推理、模糊化和去模糊化的理论，构建了基于模糊理论的变压器故障诊断系统，该方法大大提高了传统方法诊断分类的准确率<sup>[19]</sup>；吴瞻宇等人将优化后的 Apriori 算法拓展到模糊属性算法中，结合 IEC 三比值法对故障特征进行提取，得出了较高的诊断准确率。

### (3) 基于神经网络的故障诊断方法

神经网络，顾名思义就是人为的通过对基础数学理论的应用以及对程序的编写来模仿人的神经元工作原理的新一代智能算法，该网络通过对大量的收集到的变压器故

障数据的训练来进行学习，建立气体的特征与故障之间的关系来进一步判断。神经网络一经提出便迅速地受到各国学者的研究追捧，它具有强大的自组织性、自学习性。电力变压器存在着非常复杂的运行工况和环境，收集到的气体含量的变化与故障特征之间存在着非线性的关系，而神经网络通过大量数据的训练解决了非线性的问题，通过多次迭代收敛来确定最终的故障类型。

付刚等人将前馈神经网络(BPNN)引入到变压器的故障诊断中，同时与模糊理论进行对比，详细的分析了两种方法的优缺点<sup>[20]</sup>；王峰等学者利用深度学习来对变压器进行故障诊断，通过提取油中溶解气体的特征，建立该特征与设备之间的联系，进而形成对变压器的故障诊断，同时考虑到不同工况下数据的波动性，引进了残差网络来对神经网络进行改进，大大的缩短了诊断的时间<sup>[21]</sup>；王阳等人设计一套针对变压器内外故障特征的提取方法，通过小波包分析、不同小波包能量的对比来提取变压器发生故障时内外差动电流引起的能量变化差异，提出了一种神经网络进行变压器内外故障识别的方法<sup>[22]</sup>；Illias H A 等人针对变压器诊断精度低的问题，引进了混合改进粒子群算法来优化时变加速度系数并结合人工神经网络，构建了变压器故障诊断模型，解决了神经网络参数选择困难的问题，提高了诊断准确率<sup>[23]</sup>。

#### (4) 基于专家系统的故障诊断方法

专家系统是一种将专家知识、经验转化为计算机可以阅读的字符，来模拟人类专家解决某类专业问题的系统，近些年来在电力行业的研究是一个热门<sup>[24]</sup>。专家系统在变压器故障诊断领域具有很好的应用，它具有一定的容错性和自适应性，可以很好的适应变压器复杂的故障类型。具体的专家系统诊断结构图如图 1.3 所示：

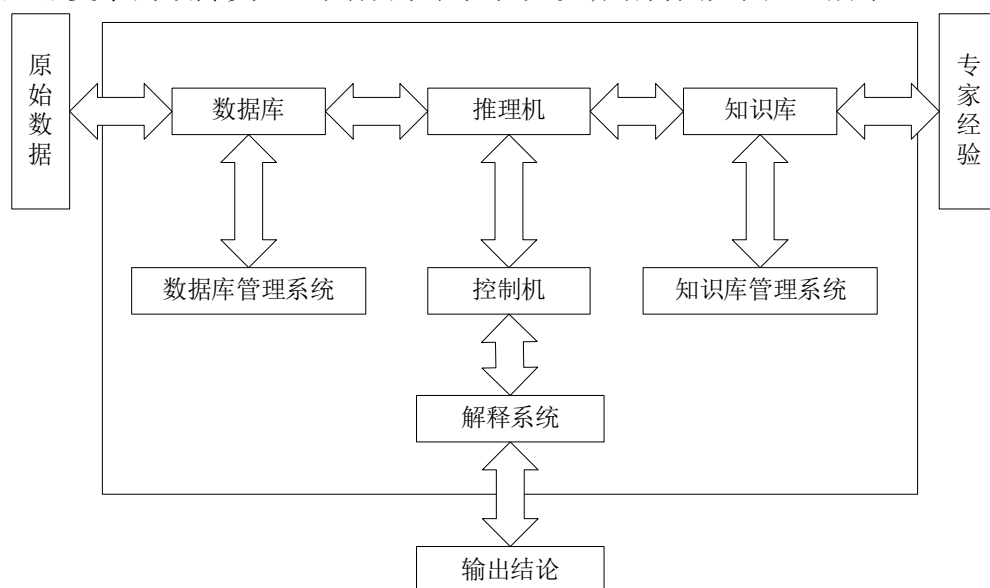


图 1.3 专家诊断系统

Fig. 1.3 Expert diagnosis system

徐阳等人针对电力变压器故障特征维度大,信息量多的特点,引入了信息融合技术对它们进行挖掘、筛选和处理,同时还分析了多维度的故障特征和故障类型之间的联系,采用了因子分析法融合了决策层信息,构建了多维度信息融合的故障诊断专家系统,既简化了数据融合又提高了故障诊断的准确率<sup>[25]</sup>;曹先平等人将专家系统和动态故障树进行融合,通过动态故障树的可视化特点直观的反应专家知识,为后续的使用提供了非常好的帮助<sup>[26]</sup>;Velasquez, R.M.A. Lara 设计了一套基于主成分分析和模糊逻辑的自适应系统,该系统主要用于对变压器的健康指数、设备的使用寿命的预测以及变压器早期故障的预测等方面,极大的解决了传统方法针对早期故障不明显导致的诊断错误的缺点<sup>[27]</sup>。

### 1.2.2 变压器故障预测发展现状

目前,随着各个国家对电力行业发展的重视,针对变压器故障诊断方法层出不穷,早在六七十年代的时候,美国、加拿大、日本等发达国家就已经开始了对变压器故障诊断方法的研究,虽然先进的检测技术能够检测出部分变压器的显著故障。但是对于一些不明显的故障或者对一些故障的发生表现不明显的设备,如何进行判定成为了难题。不过随着科学技术的进一步发展,通过一些方法来对变压器即将发生的故障进行预测,预测变压器的故障发生时间、故障发生类型以及故障发生位置逐渐成为了现实。当下主流的针对变压器故障预测的方法有很多,例如较为热门的 BP 神经网络,通过对以前变压器油中溶剂热气体含量的学习,来预测未来一段时间该变压器油中溶解的特征气体含量,之后将预测后的数据带入故障诊断系统中进行诊断来实现对未来可能发生故障类型进行预测。刘咏鑫等人将混沌序列引入到 BP 神经网络中,对网络的权重参数进行数据挖掘,构建了多参数相关的变压器故障预测的模型<sup>[28]</sup>;黄新波等构建了基于时间序列和支持向量机的变压器故障预测模型,同时采用遗传算法对自回归积分滑动模型的参数进行优化,优化了模型的预测性能,进而提高了预测准确度<sup>[29]</sup>;郑蕊蕊等针对灰色马尔科夫模型采用等维信息进行输入特征重构,同是将两种不同的灰色聚类算法相结合,并进行了改进融合,成功实现了对变压器油中溶解气体未来浓度的精准预测<sup>[30]</sup>;刘慧鑫建了基于时间序列的预测模型,并通过实验证明了时间序列方法比非时间序列有监督方法预测效果要更好。利用变压器的电气数据,进行 Boosting 迭代,将迭代后的特征作为贝叶斯网络的特征输入来实现对变压器故障的预测诊断,提高了预测的准确度<sup>[31]</sup>;针对变压器的机械故障,用小波网络来处理变压器振动信号的非线性特征,通过自适应的小波变换来实现变压器故障预测的高效、准确。该方法具有非常好的鲁棒性和收敛性,在变压器机械故障的预测上应用效果非常好<sup>[32]</sup>。后来有学者



提出了将小波分析与 BP 神经网络进行结合来实现对变压器故障的预测,后经实验发现效果很好<sup>[33]</sup>。王晶建立了改进的非等间隔灰色预测模型,利用一次指数平滑运算来对强随机性的电力变压器油中溶解的气体含量进行平滑处理,结合灰色理论建立预测模型,成功的预测变压器特征气体含量的变化趋势以及溶解含量<sup>[34]</sup>。

虽然针对变压器的故障预测众多学者已经做了非常多的研究,但是目前仍然存在的非常多的缺点。例如被广泛应用的灰色理论,虽然取得了一定的研究成果,但是由于在线监测得到的数据具有很高的离散性,同时气体含量受到运行环境的不同导致具有很高的随机性,使得基于灰色理论建造的模型精度收到了非常大的影响;神经网络以其较强的自学习能力和自适应能力强的优点受到了众多学者的研究,但是神经网络一直存在着数据量不够导致的过拟合或者欠拟合的现象,导致模型建立受到影响,模型精度有所下降。因此针对变压器的故障预测技术仍然需要进一步的提高。如何更好地利用神经网络等智能方法,成为目前的研究热点。

### 1.2.3 本文的主要研究内容

本文在分别针对变压器的智能诊断和故障预测两个方面做了详细的分析,阅读了大量国内外关于变压器诊断与预测方面的文献以及研究成果,深入总结,同时结合目前我国电力行业发展状况进行了以下几个方面的研究:

(1) 第1章详细的介绍了本文研究课题的选题背景,变压器智能诊断和故障预测在国内外的研究现状以及研究意义,分别介绍了变压器智能诊断和故障预测的研究成果和主流方法,并深入分析了每一种方法的优点以及所存在的缺点。

(2) 第2章首先分析了变压器的结构组成以及故障产生机理;其次针对变压器的故障种类进行了详细的特征分析;紧接着挖掘了变压器油中溶解气体的产气原理以及故障与特征气体之间的联系。最后对每一种故障产生的原因,伴随产生的特征气体进行了详细的介绍,深入分析了油中溶解气体含量与故障类型之间的紧密关联。

(3) 第3章首先概述了支持向量机、麻雀优化算法的数学理论基础;其次针对麻雀算法和变压器故障诊断的特点对算法进行了改进,引进了反向学习策略和萤火虫扰动策略分别对麻雀算法初始种群的选择、麻雀位置的优选进行的改进提升;紧接着利用 Matlab 对本文改进的算法进行了性能测试,证明了改进后算法的优秀性能;最后构建了基于改进麻雀算法和支持向量机相结合的变压器故障诊断模型。以五种主要的油中溶解气体为基础,结合无编码比值法对数据进行重构形成新的数据集,将新构建的数据集作为模型的特征输入,最终构建模型。结合实际现场所测数据进行模型的实例分析,证明该方法的优越性。

(4) 第 4 章首先介绍了本所采用的溶解气体含量预测模型极限学习机的理论基础；然后利用改进的麻雀算法提升极限学习机的回归性能，提高模型的预测精度；随后搭建了基于提升极限学习机的变压器油中气体含量预测模型，以五种特征气体含量作为特征输入，分别进行了预测，结果显示提升极限学习机模型具有很高的预测精度。最后在精准预测的基础上结合了第三章的故障诊断模型，构建了变压器故障预测模型，通过对 200 组已知故障的实际数据的实验分析，证明了该模型良好的预测性能。

#### (5) 结论与展望

首先详细的总结了本文针对大型变压器的智能诊断及故障预测方面做出的研究工作，通过实例分析证明了本文提出的两种模型的实用性，可以应用于实际生产生活中。紧接着针对本文未研究到的地方以及分析不够到位的地方提出了未来该方向研究的重点，为未来研究学者提出了一些意见。



## 第2章 变压器故障产生机理和特征分析

变压器作为电力系统中的“桥梁”，其故障种类非常的繁杂，引起故障的原因也非常的多。但是总体来说，变压器故障类型主要分为：电故障、热故障和机械故障。电故障主要包括：局部放电故障、高能放电故障、低能放电故障。热故障主要分为：低温过热故障、中温过热故障和高温过热故障。而机械故障主要是表现在绕组松动、匝间绝缘故障等，不过由于机械故障最终的体现在温度上，因此有的学者将其划分到热故障的范畴之中。

由于变压器内部存在着绝缘油液和绝缘固体，在发生故障时内部的温度上升导致绝缘物体内的碳氢化合物发生裂解、重组，生成各种不同的特征气体，根据故障类型的不同，裂解产生的能量和温度变化也不同，进而导致不同的特征气体在油中的含量也就相应不会相同。

### 2.1 变压器的结构和故障机理

#### 2.1.1 变压器基本结构与故障分类

油浸式变压器作为我们常见的变压器类型，主要由六大部分组成：器身、油箱、调压装置、冷却装置、保护装置和出线装置。在维修过程中需要将外面的箱体拿掉，直接对变压器除箱体以外的其余五个部分进行检查，但其中有部分装置置于套管内部，检查时具有一定的困难。变压器具体内部结构简图如图 2.1 所示，



图 2.1 油浸式变压器内部结构简图

Fig. 2.1 Internal structure diagram of oil immersed transformer

其中每一部分又含有非常多的电器元件，具体的器件如表 2.1 所示：

表 2.1 电气元件明细表  
Tab. 2.1 List of electrical components

油浸式变压器					
器身	油箱	调压装置	冷却装置	保护装置	出线装置
铁芯、 高压绕组、 低压绕组、 绝缘引线	油箱本体、 油箱附件 (阀门、接 地螺栓、放 油阀门等)	有载分接开关、 励磁分解开关	散热器、 冷却器	温度计、 液位计、 储油柜、 安全气道、 排湿装置、 过滤器	高压套管、 低压套管、 中压套管、 电缆等

通过表 2.1 中可以看出变压器电气元件种类非常多,通常变压器发生故障的主要是冷却装置、保护装置和器身。器身因处于变压器外部,因此它发生故障又称为外部故障。外部故障很容易被检修人员发现,并及时进行检修,而相反内部故障则表现在气体含量的变化上,这就需要采用在线监测技术进行监测。

变压器由于其系统的复杂程度,导致故障类型也相对复杂,具体如表 2.2 所示:

表 2.2 变压器故障类型  
Tab. 2.2 Transformer fault types

变压器故障类型			
变压器本体	变压器结构	回路分类	故障部位分类
内部故障	铁芯故障	电路故障	绝缘故障
外部故障	附件故障	磁路故障	铁芯故障
	油质故障	油路故障	开关故障
	绕组故障		绕组故障
			套路故障
			引线故障
			匝间故障

### 2.1.2 变压器故障产生机理

由于变压器故障种类非常多,产生的机理也不尽相同,其中主要的常见的故障如下。

#### (1) 绕组故障和铁芯故障

绕组故障作为机械故障,其最终的表现形式为绕组部分温度升高,因此也可以将其称为热故障。变压器由于其特殊性,绕组位于变压器的内部,它发生故障一般会导致变压器停机检修。绕组故障主要是由于变压器的负载增大,内部散热系统老化导致散热不及时,致使绕组局部温度过高,发生绕组的绝缘性故障;此外由于变压器的安装、生产、设计等原因导致绕组受到内部线路产生的电磁的影响,进而发生故障;由于变压器长时间的工作导致的冷却装置的老化,使得内部散热系统出现故障,油路发生堵塞也会产生绕组故障。

铁芯故障同样作为机械故障,它发生后的故障表现形式也是热故障类型,但是形

成铁芯故障的原因，相对较复杂主要分为四类：一、运行环境和工况的不同导致的局部过热引起故障；二、铁芯出现了多点触地的现象，致使出现局部短路，导致发热；三、组成变压器铁芯绕组的系统出现相互关联故障；四、铁芯的加固螺栓对地的绝缘出现了裸漏，导致螺栓带电，引发故障。五、其他零件的损坏，导致的铁芯发生故障。

### （2）热故障

热故障作为变压器故障的最主要表现形式之一，一直以来都是研究者们研究热点，究其原因，主要是因为热故障会破坏变压器的绝缘系统，加快变压器绝缘系统的老化，从而加速变压器的损坏，降低使用寿命。一旦长时间发生高温过热故障，还会导致变压器发生爆炸，危害性非常大。变压器的热故障主要的产生原因是：内部电器零件间的接触不良、电磁故障和一些导电体的微小故障。由于发现不及时就会导致出现不同程度的过热故障，进而影响整个变压器的工作。据调查显示，热故障在变压器的故障类型中占有很大的比重，同时在热故障中有接近一半的故障是由于分接器开关接触不良导致，有将近 15%是由于内部导线过热导致；其他的例如线圈漏磁、其他开关接触不良都会导致热故障的发生。热故障最主要的表现形式就是绝缘油液中烃类含量的变化，其中主要是  $\text{CH}_4$  和  $\text{C}_2\text{H}_4$  含量的变化。据研究发现，随着故障的发生，变压器油液的温度也会提升，随着温度的逐渐升高， $\text{C}_2\text{H}_4$  含量上升非常的迅速。

### （3）电故障

变压器的电故障是指在内部高压电场的长时间放电过程中，绝缘介质被电流击穿，导致变压器内部出现被腐蚀的现象。电故障被分为局部放电和高能放电。局部放电是指内部的一些元件年久失修导致的局部外露，局部放电虽然能量转换比较小，但是如不及时发现并且修理，就会进一步的导致重要设备被击穿，出现严重的运行故障。此外电故障还有一种低能量的火花故障，该故障主要是由于导线的损坏、铁芯的不良接触而导致的。高能放电故障主要是电弧放电故障，它是由于引线突然断裂、分接开关粘连、绕阻间发生电流击穿，是变压器最为严重的故障，必须要严加防范。电弧故障的特点就是破坏性非常大，可能突然发生就会导致变压器直接瘫痪，其次它产气速度非常的快，可以直接导致内部绝缘系统被击穿，绝缘材料发生碳化或者爆炸。因此，电弧故障一直是变压器状态维修的重要检查指标。一旦发生后果不堪设想。

### （4）其他故障

不同变压器运行的环境也有所不同，此外由于变压器所处的地理位置、季节气候的不同，导致各地的湿度和降雨量的不同，变压器受潮出现外部箱体生锈，密封设备老化，密封性能下降，空气中的水蒸气进入变压器的内部，随着变压器长时间的运行，微小的损坏便会引起放电故障，在放电作用下，水汽发生电解反应，由于箱体的材料

是铁制材料，铁在放电的作用下与水汽发生化学反应，产生大量的氢气、氧气，这就导致两种气体含量占比明显增高。当水汽进入变压器中，一些精密的设备由于水汽的干扰，任何部位都会发生短路，而导致能量的变化，进而发生不可逆转的故障。

此外，变压器在运输的过程中，由于工作人员的操做不当导致箱体或者某些部位被碰撞，刮划等破坏，导致内部的绕组松动、铁芯或夹件脱落，绕组线圈脱落引起的机械故障，也会导致内部的能量发生变化，引起放电故障的发生。

## 2.2 变压器故障的特征分析

变压器产生故障的主要特征体现在溶解于油液中不同气体含量的变化上，其中最主要的就是  $H_2$ 、 $CH_4$ 、 $C_2H_4$ 、 $C_2H_6$ 、 $C_2H_2$  这五种气体含量的变化，此外还包括一些少量的  $CO_2$  和  $CO$  的变化。其中故障气体主要是由于变压器内部的绝缘材料和绝缘介质在发生电故障和热故障时所产生的。绝缘材料或者绝缘介质在受到电、光、温度等的影响下，发生了缓慢的氧化还原反应、裂解反应以及材料的碳化过程，在这种化学反应的过程中，形成了一些氢、低分子烃气体以及一些氧化物、糠醛物质，再通过化合键之间的重新组合生成特征气体。变压器的电故障和热故障正是因为这个原因，通过故障发生时的高能量变化而催生不同的特征气体，具体故障对应的气体如表 2.3 所示。

表 2.3 故障类型对应气体成分  
Tab. 2.3 Gas composition corresponding to fault type

故障类型	主要特征气体成分	次要特征气体成分
油过热	$CH_4$ 、 $C_2H_4$	$H_2$ 、 $C_2H_6$
油和纸多热	$CH_4$ 、 $C_2H_4$ 、 $CO_2$ 、 $CO$	$H_2$ 、 $C_2H_6$
油纸绝缘局部放电	$H_2$ 、 $CH_4$ 、 $CO$	$C_2H_2$ 、 $C_2H_6$ 、 $CO_2$
油中电弧放电	$H_2$ 、 $C_2H_2$	$CH_4$ 、 $C_2H_4$ 、 $C_2H_6$
油中电火花放电	$H_2$ 、 $C_2H_2$	/
油和纸中的电弧放电	$H_2$ 、 $C_2H_2$ 、 $CO_2$ 、 $CO$	$CH_4$ 、 $C_2H_4$ 、 $C_2H_6$

现阶段绝大多数的换流站都会安装变压器油色谱在线监测装置，来实时监测内部油液能量以及特征气体含量的变化。如图 2.2 所示为油色谱在线监测器；图 2.3 所示为在线监测界面。



图 2.2 油色谱在线监测

Fig. 2.2 Online monitoring of oil chromatogram

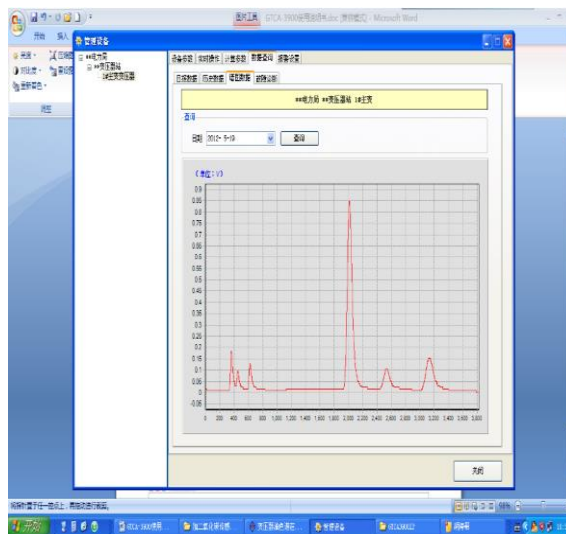


图 2.3 在线监测界面

Fig. 2.3 Online monitoring interface

### 2.2.1 故障气体产生来源

在发生电故障和热故障的过程中，变压器产生的特征气体主要来源于以下几种方式：

#### (1) 内部绝缘材料的分解

固体绝缘材料的裂解主要体现在  $\text{CO}_2$ 、 $\text{CO}$  量的变化，这主要是因为固体绝缘材料的主要成分是纤维素，纤维素主要含有的成分为碳、氢、氧三种元素组成的高分子聚合物，在电故障和热故障的发生过程中会释放很高的能量变化，当温度升到  $105^\circ\text{C}$ - $300^\circ\text{C}$ ，变压器内部的固体绝缘材料就会发生裂解、碳化反应。由于固体绝缘材料中的主要化合键成分与变压器油液中的化合键成分有很大的不同。在相同的温度下，固体绝缘材料因高温裂解产生的  $\text{CO}_2$ 、 $\text{CO}$  要远远的高于绝缘油液的产生。因此，很多学者将  $\text{CO}_2$ 、 $\text{CO}$  两种气体的含量作为变压器固体绝缘材料的劣化标准。

#### (2) 绝缘油液的分解

绝缘油液作为变压器内部主要的绝缘物质，其主要成分是分子组成成分不同的碳氢化合物混合而成，而温度上升和能量冲击是直接影响绝缘油液的分解。当变压器发生过热故障时，内部温度会发生显著的变化，绝缘油液在温度的变化过程中就会发生不同程度的裂解。当温度上升到  $500^\circ\text{C}$  左右的时候，油液就会裂解产生乙烯，同时在温度上升的过程中甲烷和乙烷也逐渐产生。当温度达到  $500$ - $800^\circ\text{C}$  时，绝缘油液发生碳化而产生碳粒。当温度升到  $800$ - $1200^\circ\text{C}$  时，油液裂解产生乙炔，由于电弧放电所产生的能量非常高，所以电弧放电会产生大量的乙炔。

同样变压器电故障也会引起绝缘油液的分解，放电量的大小直接影响裂解产生的

气体成分。研究发现, 变压器绝缘系统由于生产的关系, 导致器身之中存在绝缘薄弱的地方, 而局部放电故障常常发生在这些绝缘不佳的部位。局部放电所产生的能量一般比较低而油液中最为脆弱的 C-H 键在这种低能量的作用下通过离子反应发生断裂, 并重新结合形成  $H_2$ 。伴随着内部绝缘系统的老化, 局部放电部位逐渐的增多, 电弧放电的形成, 变压器内部的能量累计迅速增加, 在这种高能量的作用下 C-C 键发生断裂并进行重新组合, 形成 C=C 为主体  $C_2H_2$  和  $C_2H_4$  气体以及 C≡C 为主体的  $C_2H_6$  气体。因此, 通过油中特征气体含量的变化可以区分故障的严重程度。

### (3) 其他的产气来源

除了变压器内部绝缘系统的分解和劣化而产生的气体外, 还会有诸多原因引起气体的生成。

一、不同变压器运行工况以及工作环境的不同导致变压器生锈发生劣化, 空气中的气体进入到变压器内部, 其中也包含部分故障气体。

二、变压器绝缘油液在生产精炼过程中, 内部气体没有完全除去而带入到变压器内部; 在变压器温度上升到一定程度后, 固体物质内存在的少量气体被析出, 溶解在变压器油液中。

三、变压器在安装的过程中, 由于热油循环处理, 会产生微量的气体; 此外在焊接本体油箱与其他设备的时候, 也会形成  $CO_2$  和少量的  $CH_4$  气体; 同样焊接其他辅助设备的时候, 也会留下残油在变压器箱壁之上, 这些残油在高温、高能量的冲击下也会形成一部分少量的故障气体。

四、在进行变压器的检修过程中, 由于操作人员的操作不规范也会导致故障气体的产生。例如: 进行有载调压变压器调压的过程中, 开关油室中的油会渗透进主油箱之内; 有载电压在开启的过程中开关处在某一特定位置的时候, 会有短暂的放电现象, 此放电会产生一定的故障气体残留。

### 2.2.2 变压器内部气体含量标准

变压器在刚投入使用的时候, 其内部绝缘系统处于全新的状态, 而此时绝缘油液中的故障气体含量也处于极低的水平, 常见的几种故障气体因其含量微小可以忽略不计,  $O_2$  和  $N_2$  含量非常的高, 具体的正常含量值如表 2.4 所示。正常运行的变压器中  $O_2$  含量大约在 25% 左右, 而由于变压器的保护系统和装置的存在导致  $N_2$  含量相对于空气中含量有所降低。同样的在正常运行的变压器内部之中  $CO_2$ 、CO 两种气体的含量相比于空气中要高出一个量级, 它们的含量是随着服役的年限增长而增长的, 时间越久远含量占比就越高, 因此, 可以通过在线监测  $CO_2$ 、CO 两种气体含量的变化来监测变

压器的老化程度。

当变压器发生轻微故障之时， $H_2$ 、 $CH_4$ 、 $C_2H_4$ 、 $C_2H_6$ 、 $C_2H_2$  和  $CO$  等故障气体含量也会发生微小的变化，因此以这几种气体含量的变化作为变压器运行状态的判别标准非常实用。国内外针对变压器内部气体含量的高低，制定了一定的极限标准来作为变压器运行状态的判别准则，如表 2.4-2.5 所示。而表中所列的数据只是警戒值，并非故障值。如表 2.6 所列的各种气体含量的注意值和警戒值所示，当气体达到含量警戒值的时候，就需要检修人员对变压器其进行停机检修。此外产气速率也可作为判别标准；因此在对变压器的在线监测过程中，不仅仅要关注当前含量的气体变化，还要注重未来气体含量的发展趋势。

表 2.4 变压器正常运行含量极限值 (ppm)

Tab. 2.4 Limit value of transformer normal operation content (ppm)

气体	$H_2$	$CH_4$	$C_2H_4$	$C_2H_2$	$C_2H_6$	总烃
极限含量	150	45	65	5	35	150

表 2.5 国外正常运行变压器油中气体含量极限值 (ppm)

Tab. 2.5 Limit value of gas content in transformer oil in normal operation abroad (ppm)

运行时间	$H_2$	$CH_4$	$C_2H_4$	$C_2H_2$	$C_2H_6$	$CO$	$CO_2$
3年	200	100	152	15	100	500	6000
5年	250	200	300	35	200	1000	11000

表 2.6 特征故障气体数值含量表

Tab. 2.6 Characteristic fault gas content table

(单位:  $\mu L/L$ )

气体种类	正常值	注意值	故障值
$CH_4$	30	45	/
$C_2H_2$	<5	5-10	>10
$C_2H_4$	45	65	/
$C_2H_6$	25	35	/
$H_2$	<100	100-200	>200
总烃	<100	100-200	>200

## 2.3 变压器故障类型与特征气体的关联

变压器故障种类繁多，形成故障的原因上文已经进行了详细的阐述，根据故障产生的原因研究者将故障分为 9 类，后根据 IEC60599: 2014《运行中矿物油浸电气设备



溶解气体和游离气体分析的解释导则》将其合并为六种，即低温过热（ $<300^{\circ}\text{C}$ ）、中温过热（ $300^{\circ}\text{C}-700^{\circ}\text{C}$ ）、高温过热（ $700^{\circ}\text{C}$ 以上）、局部放电、低能放电、高能放电这六种，由于上文我们提到的局部放电会产生较低的能量变化，所以将二者合并为低能放电；将中温过热故障和低温过热合称为中低温过热，再加上正常状态，目前变压器主流的故障种类就是中低温过热、高温过热、低能放电、高能放电、正常这五类。

具体的故障类型与特征气体的详细关联如表 2.7 所示。

表 2.7 故障类型与特征气体的关联

Tab. 2.7 Correlation between fault types and characteristic gases

序号	故障类型	特征气体关联
1	正常	油液中 $\text{O}_2$ 和 $\text{N}_2$ 含量较高， $\text{CO}_2$ 和 $\text{CO}$ 含量较低， $\text{H}_2$ 、 $\text{CH}_4$ 、 $\text{C}_2\text{H}_4$ 、 $\text{C}_2\text{H}_2$ 、 $\text{C}_2\text{H}_6$ 等气体含量处于正常范围
2	中低温过热	总烃的含量 $\text{CH}_4$ 较高且含量高于， $\text{C}_2\text{H}_4$ 、 $\text{C}_2\text{H}_2$ 占总烃含量的2%左右
3	高温过热	总烃含量高， $\text{H}_4$ 含量低于总烃含量的5.5%， $\text{H}_2$ 的含量占比大约为总烃含量的27%
4	低能放电	总烃含量不高， $\text{C}_2\text{H}_2>10\mu\text{L}/\text{L}$ 高于总烃的25%， $\text{H}_2>100\mu\text{L}/\text{L}$ 高于氢总量的90%
5	高能放电	总烃含量的非常的高， $\text{C}_2\text{H}_2$ 占比为18%-65%，是总烃含量的主要成分

根据调查显示，目前我国国家发生的变压器故障主要是热故障类型占比较多，过热故障占整个故障种类的 60%左右，其余的故障按照占比从高到低依次是高能放电、低能放电。

## 2.4 其他特征与变压器故障的关联

油中溶解气体分析法作为目前最主流的变压器故障诊断的方法，除此之外还有一些特征也可以作为变压器故障诊断的辅助判别依据。具体方法如下所示：

### （1）产气速率判别法

特征气体在产生的过程中，不同故障类型对应的能量变化也是不尽相同的，这种能量变化的所引起的特征气体的产生速率也就会不同，通过对变压器故障特征的调查发现，部分设备即使在没有发生故障的时候内部的特征气体含量已经超标，相反的有些变压器已经发生明显的故障，但是却并没有反映在气体的含量之上，监测显示含量也并没有超标。这是因为在正常运行的状态下，变压器依然会产生气体，因此达到注



意值却没有发生故障。通过监测显示特征气体的产气速率可以避免这一问题的出现，因此对变压器实施气体产生速率监测就显得非常有必要。产气速率法是指通过将某种气体的在一段时间内气体体积分数的增长状况来衡量变压器是否有故障发生。从定义中可以看出该方法可以快速的识别变压器是否有故障发生，这在一定程度上克服了通过 DGA 判别法的缺点，有效的反应内部故障的发展趋势。研究发现产气速率可以分为绝对产气速率和相对产气速率，绝对产气速率主要用来反应内部特征气体产生的速度；而相对产气速率反应的是某种特征气体含量在一定时间间隔内的增加值和原有值的比值的平均值。通过对于产气速率的监测来判断故障的发生，当产气速率达到一定数值时，就需要检修人员进行及时的检修，缩短检修周期，用以掌握变压器未来发展的情况。具体的注意数值如表 2.8-2.9 所示。

表 2.8 变压器绝对产气速率注意值  
Tab. 2.8 Precautions for absolute gas production rate of transformer

(单位: mL/d)

所含气体	开放式变压器	隔膜式变压器
H <sub>2</sub>	5	10
C <sub>2</sub> H <sub>2</sub>	0.1	0.2
CO <sub>2</sub>	100	200
CO	50	100
总烃	6	12

表 2.9 不同特征气体绝对产气速率注意值  
Tab. 2.9 Absolute gas production rate of different fault gases

(单位: mL/d)

气体	H <sub>2</sub>	CH <sub>4</sub>	C <sub>2</sub> H <sub>2</sub>	C <sub>2</sub> H <sub>6</sub>	C <sub>2</sub> H <sub>4</sub>	CO <sub>2</sub>	CO	总烃
<110KV	5.34	2.52	0.59	2.35	3.69	0.45	2.42	4.07
<220KV	7.97	3.21	13.45	4.05	3.9	1.9	3.08	3.5
<500KV	21.27	5.71	2.42	11.92	7.76	4.65	5.95	5.48

## (2) 油特性实验分析

油特性分析是指变压器在运行的过程中绝缘油液在抗击故障发生带来的能量变化冲击过程中，发生的一些变化。这其中主要包含了酸值、糠醛含量、介质损耗因数、水含量等指标，通过监控这些指标的变化情况，来发现变压器的潜伏性故障。具体各个指标的注意值如下所示。

### 一、酸值

变压器油中的酸度，直接影响到变压器的整个绝缘系统的劣化速度，因此，对于

油中酸度的监测是非常有必要的。具体注意值如下表 2.10 所示

表 2.10 不同额定电压对应的酸值注意值

Tab. 2.10 Acid value of different rated voltage

变压器额定电压等级 (KV)	<230	>230
注意值(mg/g)	0.1	0.07

## 二、糠醛含量

油中糠醛含量作为判别变压器绝缘老化程度的重要指标，其是通过纤维素在故障发生过程中通过裂解而生成呋喃化合物。油中的呋喃化合物含量越小，变压器老化越小。反之则越大。因此，加强油中糠醛含量的监测，对发现变压器潜在故障是非常必要的。具体如表 2.11 所示。

表 2.11 不同糠醛含量的变压器对应的绝缘性能

Tab. 2.11 Insulation performance of transformers with different furfural content

糠醛含量 (mg/L)	0.5	1-2	4
绝缘纸绝缘性能	劣化中期	劣化严重	绝缘失败

## 三、介质损耗因数

变压器在运行过程中，由于工况的变化会导致绝缘油液出现不同程度污染；介质损耗因数便是用来形容油液污染程度的指标，可以很好的反应变压器潜在故障。具体注意值如表 2.12 所示。

表 2.12 不同额定电压对应的介质损耗注意值

Tab. 2.12 Dielectric loss values corresponding to different rated voltages

变压器额定电压等级 (KV)	<330	>500
注意值	0.04	0.02

## 四、水含量

水含量不仅关系着变压器的稳定运行，而且影响着油中溶解特征气体含量。因此对水含量的监测是非常有必要的。具体如表 2.13 所示。

表 2.13 不同额定电压对应的油中水含量注意值

Tab. 2.13 Water content of oil corresponding to different rated voltage

变压器额定电压等级 (KV)	<220	>330
注意值 (mg/L)	25	15

## 2.5 本章小结

本章首先详细介绍了变压器的组成结构以及故障产生的机理，紧接着在掌握变压器结构基础上重点分析了变压器的故障特征，研究发现各类部件损坏所带来的故障会造成变压器内部能量和温度的改变，不同温度使得溶解的特征气体种类和含量也大不相同；然后针对不同类故障引起的变压器油液中溶解的气体含量的变化，深入分析变压器故障气体的产生原理，详细的列出了热故障、电故障以及机械故障所带来的变压器特征气体含量的变化；之后列出了变压器内部气体含量的标准值。不同类故障其对应的总烃和氢气的含量也不一样，通过详细调查明确了特征气体含量具体的标准值和警戒值，为后文故障诊断提供了理论基础；最后深入研究了变压器故障类型与特征气体含量的具体关系。故障类型不同判定依据也不同，所反映的故障与特征气体的种类、气体含量的关联程度也不同，为后文利用故障特征气体的预测值，来预测变压器故障的发生提供了理论依据。

### 第 3 章 基于 FA-ISSA-SVM 的变压器故障诊断

现阶段针对变压器结构和故障产生特点，油中溶解气体含量分析法（DGA）被众多学者广泛应用于变压器的故障诊断领域。目前研究方法多采用单一的智能方法，例如：神经网络诊断法、模糊理论诊断法、时间序列预测法和灰色理论预测法等。随着机器学习和深度学习的崛起，多种算法结合的方式已经成为研究热点，通过众多学者研究成果显示，多种方法相结合的方式在变压器的故障诊断领域具有很好的效果。

鉴于以上的发现，本文构建了一种基于麻雀算法优化支持向量机的变压器故障诊断模型，但在实验过程中发现麻雀算法容易陷入局部最优解而无法跳出，使得算法的寻优能力大大下降，导致构建的模型准确率下降。为了进一步提升模型诊断准确率，本文将引进反向学习策略、萤火虫扰动策略来改进麻雀算法的全局寻优能力，实例分析表明，该方法在变压器故障诊断领域具有良好的效果。

#### 3.1 变压器故障诊断方法

如何进行变压器的故障诊断，仅仅依靠传统方法显然是不够用的，因此将智能优化算法引入到变压器故障诊断领域成为目前主流的研究热点。在第一章本文已将详细的陈述了目前国内外热门的智能算法，主要包括：神经网络、专家系统、模糊理论、支持向量机等，具体算法的特点如表 3.1 所示。通过查阅国内外的文献对比发现支持向量机模型结构简单，鲁棒性和泛化能力相当出色，本身针对小样本的学习效果更好，正好与变压器故障数据少的特点相吻合，因此本文采用支持向量机模型作为变压器的故障诊断模型。

表 3.1 变压器故障常见诊断方法比较  
Tab. 3.1 Comparison of common transformer fault diagnosis methods

算法	特点
特征气体法	能够直观判断故障发生与否，但不能确定故障类型
比值法	简单、方便，但是编码不全，故障编码有所缺失
模糊理论	能够很好的处理故障类型与征兆之间的模糊性问题，但是缺乏数学理论支持，人为干预较多。
专家系统	可以对大量的实验数据和监测信息进行全面评估，但是缺乏规则的表示。
BP神经网络	分类效果较好，但是容易出现过拟合现象
支持向量机	分类效果明显，理论完善，避免了过拟合现象的发生，但算法的参数选择需要更具经验来选取

支持向量机（SVM）也被称为支持向量网络，是近些年来被广泛应用的分类回归的机器学习算法。从学术角度来讲，SVM 是最接近深度学习的机器学习算法。现行的 SVM 相当于神经网络的单个神经元，不同的也仅仅是所用的损失函数有所不同；至于非线性的 SVM 则相当于两层的神经网络，如果添加多个核函数，则完全可以模仿多层神经网络的工作原理<sup>[35-37]</sup>。

通过查阅文献和相关资料可知，支持向量机在分类回归问题中，主要是通过超平面的选择来做为决策边界，将数据进行一分为二，使得 SVM 模型在数据上的分类误差尽可能地小。如图 3.1 所示：




图 3.1 SVM 分类原理图

Fig. 3.1 Schematic diagram of SVM classification

对于线性可分的情况，最优分类超平面的方程可以用下式表示：

$$\alpha x + b = 0 \quad (3.1)$$

其中  $\alpha$  代表超平面的法向量； $b$  为常数项。

如图 3.1 所示，最优超平面是指当分类间隔最大时所存在的平面。SVM 是基于统计学的机器学习算法，目前已经被广泛地应用于电力行业的各种分类回归问题，尤其是针对电力行业的故障诊断领域，通过式（3.1）来将高位数据特征进行分类。

从图中可以看出，支持向量是指距离最优超平面最近的两个样本向量。其中一组向量用来确定最优分类超平面。该平面就会将优化问题进一步转化而求解。

假设线性可分得样本为  $(x_i, y_i)$ ， $(x_i, y_i), x \in T^L, y \in [-1, 1], i = 1, 2, 3, \dots, n$ ，满足

$$y_i(\alpha g x_i + b) \geq 1 \quad (3.2)$$

通过上式可以将分类间隔表示为  $2/\|\alpha\|$ ，因此当  $\|\alpha\|^2$  取值最小时，分类的间隔将会达到最大的间隔。所以最优超平面必须要满足式（3.2）和  $\|\alpha\|^2/2$  取值最小的平面，而处在最小平面上的点就是支持向量。

而对于非线性问题，需要考虑最大分类间隔和最小错分样本两种问题，从而推知

广义的最优超平面，将松弛变量  $\tau_i (\tau_i \geq 0)$  以及惩罚因子  $C$  ( $C > 0$  且为常数) 引入到最优超平面内，同时通过  $X = \phi(x)$  将  $x$  映射到高维空间之内。通过此种方式得出对应的优化问题就变成了

$$\min_{\alpha, b, \tau} \frac{1}{2} \alpha^T \alpha + C \sum_{i=1}^n \tau_i \quad (3.3)$$

对应的约束条件变为：

$$\begin{cases} y_i [\alpha^T \phi(x_i)] \geq 1 - \tau_i \\ \tau_i \geq 0 \\ i = 1, 2, \dots, n \end{cases} \quad (3.4)$$

具体映射过程如图 3.2 所示。




图 3.2 二维到三维的映射  
Fig. 3.2 Mapping from 2D to 3D

通过上文所述，当问题达到线性可分的情况，其中达到既定经验风险值为零时的平面就是最优超平面。相反遇到线性不可分问题的时候，广义上的最优超平面是在对错分样本控制的前提之下来寻找期望风险最小的超平面。从上述可以看出，无论是线性还是非线性都是在期望风险界上寻找最优结果。

然而，在现实中，大多数类别问题是非线性或不可逆的。选择正确的映射函数后，函数投影到低维空间的线性非线性问题将转换为线性微分问题。但是，如果小规模数据混合与高维一致，由于空间维数的急剧增加，这使得品牌空间中的超空间优化分类更加困难。因此，随着研究的进展，在支持向量算法中引入了核心函数的思想。支持向量机的算法中的核函数主要有以下几种：

(1) 线性核函数

$$K(x, y) = x^T y = x \times y \quad (3.5)$$

(2) 多项式核函数

$$K(x, y) = (x^T y)^d \quad d \geq 1 \quad (3.6)$$

(3) 双曲正切核函数

$$K(x, y) = \tanh(\gamma(x^T y) + r) \gamma > 0, r < 0 \quad (3.7)$$

(4) 高斯径向基核函数

$$K(x, y) = e^{-\frac{\|x-y\|^2}{2\sigma^2}}, \sigma > 0 \quad (3.8)$$

(5) 拉普拉斯核函数

$$K(x, y) = e^{-\frac{\|x-y\|}{\sigma}}, \sigma > 0 \quad (3.9)$$

不同的核函数根据不同的数据集的特征，表现出的效果也完全不同。但是不管哪种核函数其在选择过程中都必须满足 Mercer 条件，具体的如下：

对称函数  $K(x, y)$ ，其中  $x, y \in T^L$ ，一个映射函数  $\varphi$  满足： $T^L$  到  $F$  的映射，将其表示成为特征空间的内积运算，即  $K(x, y) = [\varphi(x) \times \varphi(y)]$  是成立的。而对使  $\int g^2(x)dx < \infty$  的任意不恒等于零的  $g \in T^L$ ，则下式成立：

$$\iint K(x, y)g(x)g(y)dxdy \geq 0 \quad (3.10)$$

引入核函数后，利用拉格朗日乘子就可以求解式 (3.11) 的最大值。

$$Q(\alpha) = \sum_{i=1}^m \varphi_i - \frac{1}{2} \sum_{i,j=1}^m \varphi_i \varphi_j y_j (x_i, y_j) \quad (3.11)$$

$\varphi_i$  为拉格朗日乘子。求得最优得分分类函数为：

$$f(x) = \text{sgn}(\sum_{i=1}^m \varphi_i y_i K(x_i, y_i) + b) \quad (3.12)$$

通过上述对 SVM 理论知识的陈述，可以将支持向量机分类器结构表示为如图 3.3 所示。




图 3.3 支持向量机分类器图

Fig. 3.3 Classifier diagram of support vector machine

由上图可以知道 SVM 网络的输出,是由中间层各类节点的一种线性组合,而层中的每一个节点都有相对应的输出和内积,上述图中的  $K(x, x_i)$  便是核函数,基于支持向量机的原理以及上述的结构原理可以归纳出支持向量机具有以下几类特点:

(1) SVM 是将输入的数据集进行升维,从而使得非线性的问题变得线性可分。

(2) SVM 是基于结构风险最小化原则建立的算法结构,这很好的解决了过拟合、过学习的缺点。

(3) SVM 的分类准确率与所输入的维数并无关系,而是取决于训练样本支持向量比例。

(4) SVM 是机器学习算法,可以避免局部极小值的缺点。

(5) 核函数和惩罚因子作为支持向量机最主要的两个参数,但是它们的选择会针对不同的问题而产生不一样的效果。因此,关于核函数和惩罚因子的选择问题一直是众多学者研究的热点。

本文正是针对 SVM 的核函数和惩罚因子难以选择的特点,选择麻雀搜索算法进行寻优,选择出最优的核函数和惩罚因子参数,来进一步提高算法的运算速度和诊断精度。

## 3.2 智能优化算法

上文我们详细介绍了支持向量机诊断模型的理论知识,但是该网络中直接影响分类精度与数据样本维数的惩罚因子(C)和核函数自由参量(g)的选择,大大影响着故障诊断的精确度,而群体智能优化算法的应用可以有效地解决参数寻优的问题,因此本文选择麻雀搜索优化算法作为参数寻优方式。

### 3.2.1 麻雀搜索优化算法

麻雀搜索优化算法(Sparrow search optimization algorithm, SSA)是本国学者薛建凯于 2020 年提出的,该方法主要是通过模拟自然界中的麻雀捕食行为,通过捕食者、警惕者和加入者之间的关系来更新最优的麻雀位置,用以模型参数寻优<sup>[38-40]</sup>。

根据我们对麻雀行为的了解,薛健凯学者将其用数学理论知识进行建模,为了使算法更加简洁,现制定相应的规则,具体规则如下:

(1) 将麻雀种群中负责搜寻食物的一部分麻雀定义为发现者;通过发现食物丰富领域来为其他的麻雀提供位置以及方向。

(2) 将顺着发现者提高的食物来源进行加入搜索的麻雀定义为加入者,加入者主要是通过加入到麻雀种群的搜索,来提高其在种群中的适应度值。

(3) 将处在整个种群边缘的麻雀,定义为警惕者;警惕者主要是负责发现危险的



到来，并发出警报，以提醒整个种群进行迁徙。

(4) 发现者和加入者的身份需要动态变化，不断转变；只要发现更好的食物源，那么每一个麻雀都会成为加入者。同样的每一个麻雀也都会成为发现者。同时加入者的能量是低于发现者的，在整个种群中的觅食地位也是由于能量的高低所决定的。

(5) 在整个种群的觅食过程中，加入者为了获取更好的种群位置，时刻监控着发现者的位置，一旦发现者发现更好的食物来源，那么加入者便会争夺食物资源。

算法设计：

首先假设一个有  $N$  只麻雀组成的麻雀种群，具体可表示为：

$$X = \begin{bmatrix} x_{1,1} & \dots & x_{1,l} \\ \dots & \dots & \dots \\ x_{n,1} & \dots & x_{n,l} \end{bmatrix} \quad (3.13)$$

上式中的  $l$  为优化问题的变量维数； $n$  为麻雀种群的数量，麻雀的适应度值可用  $F_x$  表示：

$$F_x = \begin{bmatrix} f([x_{1,1}, x_{1,2}, \dots, x_{1,l}]) \\ \dots \\ f([x_{n,1}, x_{n,2}, \dots, x_{n,l}]) \end{bmatrix} \quad (3.14)$$

$f$  为适应度值的表示。

加入者是由发现者提供获取食物的位置以及搜寻的方向，因此发现者具有更加宽广的觅食范围，在每一次的迭代中，发现者的位置更新公式如下：

$$X_{i,j}^{t+1} = \begin{cases} X_{i,j}^t \times \exp(-\frac{i}{\beta \times T}) & \text{if } R < W \\ X_{i,j}^t + A \times B & \text{if } R > W \end{cases} \quad (3.15)$$

$t$  表示当前的迭代次数； $j = (1, 2, 3, \dots, l)$ 。 $T$  是最大的迭代次数； $X_{i,j}$  表示第  $i$  只麻雀在第  $j$  维中的位置； $\beta$  是  $(0, 1]$  的随机数； $R$  为预警值，是  $[0, 1]$  之间的随机数； $W$  是安全值，是  $[0.5, 1]$  之间的随机数； $A$  是服从正态分布的随机数； $B$  是一个  $1 \times l$  的矩阵，矩阵中的所有元素都为 1。

当  $R < W$  表示当前的觅食环境安全，发现者可以更广泛的搜寻食物；当  $R \geq W$  表示当前觅食的环境周围存在捕食者，并且发出警报，整个种群都要飞到其他的安全的区域进行觅食。

加入者不仅承担着觅食的任务，而且还在觅食的过程中，时刻监视着发现者倘若发现者发现了更好的食物，那么加入者便会迅速去争夺食物。加入者的位置更新公式如下：

$$X_{i,j}^{t+1} = \begin{cases} A \times \exp(\frac{X_w - X_{i,j}^t}{t^2}) & i > n/2 \\ X_q^{t+1} + |X_{i,j}^t - X_q^{t+1}| \times C^+ \times B & i \leq n/2 \end{cases} \quad (3.16)$$

$C$  表示一个所有值均为 1 或者 -1 的一个  $1 \times l$  的矩阵，并且  $C^+ = C^T(CC^T)^{-1}$ ;  $X_q$  是最优位置;  $X_w$  是全局最差位置。当  $i > n/2$  时表明第  $i$  个加入者适应度很低，需要飞往其他的地方进行觅食补充能量；相反当  $i \leq n/2$  时表明新加入的加入者已经得到了食物，不需要继续去寻找食物。

警惕者约占种群总数的 10%-20%，位置是种群随机产生的，数学表达式如下：

$$X_{i,j}^{t+1} = \begin{cases} X_G^t + \gamma \times |X_{i,j}^t - X_G^t| & f_i > f_e \\ X_{i,j}^t + H \times (\frac{|X_{i,j}^t - X_w^t|}{(f_i - f_w) + \omega}) & f_i = f_e \end{cases} \quad (3.17)$$

$X_G$  表示当前的全局最优位置； $\gamma$  是一个服从均值为 0，方差为 1 的正态分布的随机数，并且作为步长控制着参数； $H$  是一个介于  $[-1,1]$  之间的随机数； $f_i$  表示当前麻雀个体适应度值； $f_e$  和  $f_w$  分别代表的是全局最佳和全局最差的适应度值； $\omega$  是最小的常数。当  $f_i > f_e$ ，麻雀被捕食的危险性最大，此时他们正处在整个种群的边缘地带，而  $X_G$  则表示种群中安全性最高的麻雀所在的位置。当  $f_i = f_e$  表示警惕者以及发现危险并且发出了警报，整个种群开始向更安全的地方移动； $H$  则是表示种群移动的方向同时也是算式中迭代的步长。

### 3.2.2 算法的基本流程

上文对 SSA 的基本原理进行了详细的介绍，具体的算法优化流程为：

- (1) 首先随机初始麻雀种群数量并定义其他的参数，规定最大的迭代次数。
- (2) 计算并将初始麻雀种群适应度值进行降序排列，寻出最好的和最差的。
- (3) 按式 (3.15)、(3.16)、(3.17) 更新发现者、加入者和警惕者的位置。
- (4) 获取当前最优的位置，若当前最优的值为比上一次值好，则继续迭代更新；若比上一次的差则停止更新，输出当前最优值。获取全局最优值和最佳适应度值。

### 3.3 麻雀搜索算法的改进

SSA 虽然具有很高的泛化性能以及稳定的寻优能力，但是在一些复杂问题的处理上仍然存在着初始麻雀种群的质量难以优选，麻雀位置易陷入到局部最优解无法跳出的缺点，因此本文引进了反向学习策略和萤火虫扰动策略来对 SSA 进行改进提升。

### 3.3.1 反向学习策略

反向学习策略(Reverse Learning Strategy)是智能算法领域的一种新的算法,该算法是以当前解为基础,通过反向学习的机制寻找对应的反向解,然后通过与以前的解进行对比来确定最优的解<sup>[41-42]</sup>。

若  $x$  是  $[m, n]$  之间的任意一个实数,则  $x$  基于反向学习的值  $x^*$  如下所示:

$$x^* = m + n - x \quad (3.18)$$

通过上式可以得到  $x$  到  $m$  的距离  $x - m = |x - m|$ ; 同时还可以得到  $x^*$  到  $n$  的距离

$$|n - x^*| = |n - (m + n - x)| = |m - x| = x - m \quad (3.19)$$

式(3.18)和式(3.19)可以看出这两个距离是相等的。由此可将反向点的定义扩展到  $D$  维空间之中。

定义 1 设  $p = (x_1, x_2, \dots, x_D)$  为  $D$  维空间中的一个点,其中  $x_i \in (m_i, n_i), i = 1, 2, \dots, D$  那么在空间中该点的反向点为  $p^* = (x_1^*, x_2^*, \dots, x_n^*)$ , 其中  $x_i^* = m_i + n_i - x_i$ 。

在 SSA 最初始的种群选择的过程中,将式(3.13)经过式(3.19)进行反向生成操作增加种群的数量,择优选择前  $N$  个麻雀作为初始的种群数量,这样优化了初始输入数据的质量,提高了算法的优化精确度。

### 3.3.2 萤火虫扰动策略

萤火虫策略(Firefly disturbance strategy, FA)是指萤火虫之间通过尾部光亮的程度来进行相互的吸引,尾部光亮程度决定了萤火虫之间的吸引度的强弱。在 FA 中,萤火虫的光亮的主要作用是吸引其他的萤火虫个体,其假设为<sup>[43-45]</sup>:

萤火虫的相对荧光亮度为:

$$I = I_0 \times e^{-\mu \gamma_{i,j}} \quad (3.20)$$

其中  $I_0$  为萤火虫的最大相关亮度;  $\mu$  为光强吸收系数,由传播介质及距离所影响;  $\gamma_{i,j}$  为萤火虫之间的距离。

萤火虫的吸引度为:

$$T = T_0 \times e^{-\mu \gamma_{i,j}^2} \quad (3.21)$$

其中  $T_0$  为最大的吸引度。

萤火虫  $i$  被萤火虫  $j$  吸引的位置公式:

$$x_{i+1} = x_i + T \times (x_j - x_i) + \beta \times (rand - \frac{1}{2}) \quad (3.22)$$

$x_i, x_j$  为萤火虫  $i$  和萤火虫  $j$  的所在的位置;  $\beta \in [0, 1]$  为步长因子;  $rand$  为服从均匀

分布的随机数且  $rand \in [0,1]$ 。

将上述的 FA 引进到 SSA 算法中,在麻雀算法每一次按照式(3.15)、(3.16)、(3.17)更新完位置之后,将目前的位置采用式(3.22)进行位置扰动,比较扰动前与扰动后的位置,若扰动前的位置更优,则该位置为最优位置参数;若扰动后的位置更优,则此位置为当前的最优位置。

通过 FA 改进后,SSA 算法进一步提高了算法局部寻优的能力,避免了在经过麻雀算法确定位置后,忽略附近更好的位置的缺点,同时在每一次迭代后都进行扰动,极大提高了算法的精度和寻优的能力。

### 3.4 改进算法的仿真测试

为了验证改进后算法的性能,在 Matlab 中进行了算法性能的测试实验。

(1) 首先选择三种经典的函数作为算法的测试函数。如表 3.2 所示。

表 3.2 典型测试函数

Tab. 3.2 Typical test functions

序号	函数表达式	范围
1	$f(x) = \sum_{i=1}^{500} -x \times \sin \sqrt{ x }$	$[-500, +500]$
2	$F(x) = f(x) - CH \times e^{-\sum_{i=1}^4 aH \times (x - pH)^2}$	$CH = [1 \ 1.2 \ 3 \ 3.2]$ $aH \in [1, 35]$ $pH \in [0, 1]$
3	$F(x) = \frac{1}{\frac{1}{500} + \sum_{j=i}^{25} (\frac{1}{j} + \sum_{j=i}^{25} (x^T - as)^6)}$	$as \in [-32, 32]$

(2) 初始化参数设置。设种群的初始数量为 50,最大的迭代次数为 1000,空间的维度为 30。

(3) 将 SSA 和 FA-SSA 算法分别对测试函数进行了 50 次寻优实验,为了更好地说明测试效果,引进了平均迭代次数来评价 SSA 和 FA-SSA 算法的优劣程度,将实验获得的数据整理成表 3.3;图 3.4-3.6 分别表示测试函数的平均最优解随着迭代次数的变化情况。

表 3.3 函数测试结果  
Tab. 3.3 Function test result

函数	统计项	平均迭代次数
1	SSA	256
	FA-ISSA	58
2	SSA	46
	FA-ISSA	11
3	SSA	214
	FA-ISSA	34




图 3.4 函数 1 的仿真对比图

Fig. 3.4 Simulation comparison diagram of function 1

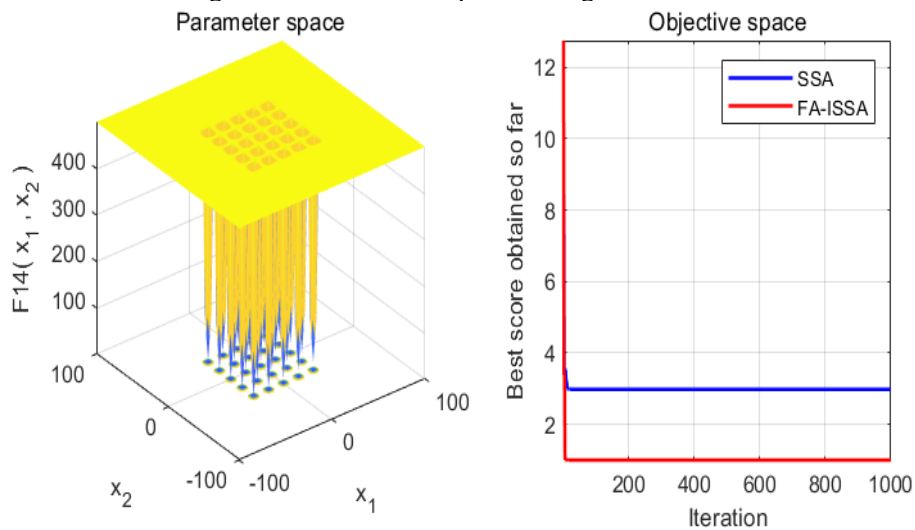


图 3.5 函数 2 的仿真对比图

Fig. 3.5 Simulation comparison diagram of function 2

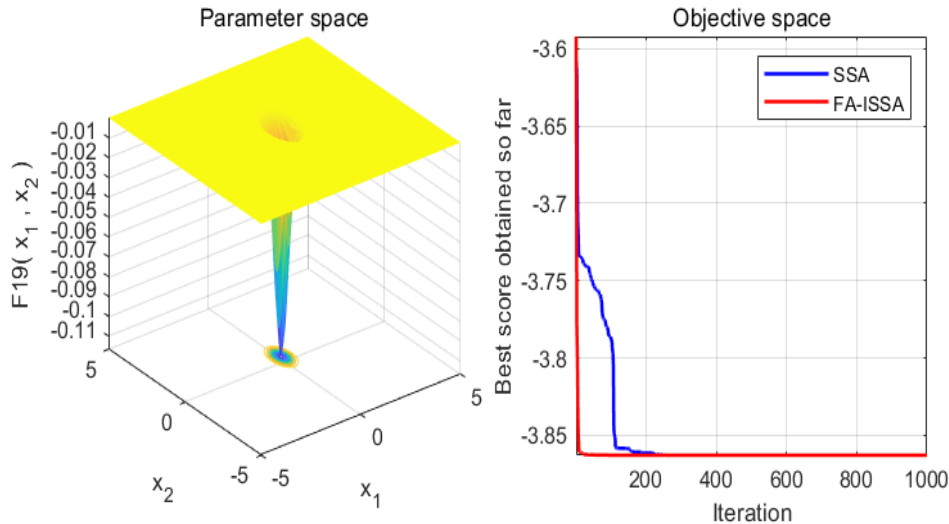


图 3.6 函数 3 的仿真对比图

Fig. 3.6 Simulation comparison diagram of function 3

图 3.4 为 FA-ISSA 与 SSA 在测试函数 1 中的迭代寻优的对比图，从图中可以看出 FA-ISSA 拥有更快的速度和更高的精度；为了排除单一测试函数的偶然性，继续选择了测试函数 2 和测试函数 3 对 FA-ISSA 和 SSA 进行测试，从图 3.5 和图 3.6 可以明显观察到 FA-ISSA 依然具有更高的性能，优化模型效果更佳。

结合表 3.3 可以看出，SSA 三种测试函数均低于 FA-ISSA 的平均迭代次数，对于测试函数 1，SSA 的平均迭代次数 256 次，而 FA-ISSA 算法的迭代次数 58 次，相比较而言提升非常的明显，同样的对于测试函数 2，SSA 的迭代次数 46 次，FA-ISSA 迭代次数为 11 次；对于测试函数 3，SSA 的迭代次数为 214 次，FA-ISSA 迭代次数为 34 次。从图 3.4-3.6 这三张测试函数优化曲线对比图，可以较明显的看出来 FA-ISSA 算法明显的要好于 SSA 算法，对于测试函数 1 和测试函数 2 可以清晰地看出，FA-ISSA 算法拥有更高的收敛精度；从测试函数 1 和测试函数 3 可以看出 FA-ISSA 有更快的收敛速度。

### 3.5 基于 FA-ISSA-SVM 的变压器故障诊断

基于 FA-ISSA 算法的优良性能，本节采用 FA-ISSA 算法来对支持向量机的核函数和惩罚因子进行全局寻优，获取最优的参数设置，以最大化支持向量机的分类功能，建立 FA-ISSA-SVM 的变压器故障诊断模型，整体提高模型的故障诊断能力，使该模型更加的适合变压器的故障诊断领域。

#### 3.5.1 模型输入输出的确定

根据第二章对变压器故障的深入分析可知，油中溶解气体的种类和含量与故障类型密切相关，因此本文以五种特征气体含量为基础，通过无编码比值方式构建了包含

气体基本含量在内的 14 个特征值作为模型的输入。具体特征规定如表 3.4 所示。

表 3.4 输入气体特征量

Tab. 3.4 Characteristic quantity of input gas

编号	DGA 特征量	编号	DGA 特征量
1	H <sub>2</sub>	8	C <sub>2</sub> H <sub>4</sub> /C <sub>2</sub> H <sub>6</sub>
2	CH <sub>4</sub>	9	C <sub>2</sub> H <sub>2</sub> /(C <sub>1</sub> +C <sub>2</sub> )
3	C <sub>2</sub> H <sub>4</sub>	10	H <sub>2</sub> /(H <sub>2</sub> +C <sub>1</sub> +C <sub>2</sub> )
4	C <sub>2</sub> H <sub>2</sub>	11	C <sub>2</sub> H <sub>4</sub> /(C <sub>1</sub> +C <sub>2</sub> )
5	C <sub>2</sub> H <sub>6</sub>	12	CH <sub>4</sub> /(C <sub>1</sub> +C <sub>2</sub> )
6	CH <sub>4</sub> /H <sub>2</sub>	13	C <sub>2</sub> H <sub>6</sub> /(C <sub>1</sub> +C <sub>2</sub> )
7	C <sub>2</sub> H <sub>2</sub> /C <sub>2</sub> H <sub>4</sub>	14	(CH <sub>4</sub> +C <sub>2</sub> H <sub>4</sub> )/(C <sub>1</sub> +C <sub>2</sub> )

其中 C<sub>1</sub> 为一阶碳氢化合物 CH<sub>4</sub>；C<sub>2</sub> 为二阶碳氢化合物 C<sub>2</sub>H<sub>6</sub>、C<sub>2</sub>H<sub>4</sub>、C<sub>2</sub>H<sub>2</sub> 体积分数之和。

### 3.5.2 特征数据的预处理

由于五种不同气体在油液中的含量具有很大差异因此需要对输入进模型中的特征进行归一化处理。归一化公式如 (3.23) 所示。

$$X_{i,j}^1 = \frac{X_{i,j}}{\sum_{k=1}^{14} X_{i,k}} \quad (3.23)$$

其中  $X_{i,j}$  表示归一化后的特征气体的值； $X_{i,j}^1$  表示原来的特征气体含量值。

### 3.5.3 输出特征状态编码

在建立故障诊断模型之前，针对变压器的故障特点，需要对变压器的故障状态进行编码。根据 DL/T 722-2014《变压器溶解气体分析和判断导则》，本文主要将变压器的故障分为：正常、中低温过热、高温过热、低能放电、高能放电五类。具体的编码如下表 3.5 所示，并将此编码做为故障诊断的输出。

表 3.5 变压器状态及编码

Tab. 3.5 Transformer status and coding

正常	中低温过热	高温过热	低能放电	高能放电
1	2	3	4	5

### 3.5.4 故障诊断模型的建立

通过上一节的对比试验，已经证明了本文改进的优化算法具有非常高的性能，因此本节主要采用的是 FA-ISSA-SVM 作为训练和测试的模型，核函数选择的是经过寻优后确定的参数值；输入方面，将气体在油液中的含量以及无编码比值经过归一化处理后作为模型的特征输入，故障编码作为模型的特征输出；参数方面，选择改进麻雀搜索(FA-ISSA)算法对支持向量机的核函数和惩罚因子进行参数寻优，最终得到的结果作为模型最终参数，根据寻优结果建立模型。具体的流程图 3.7 如下：

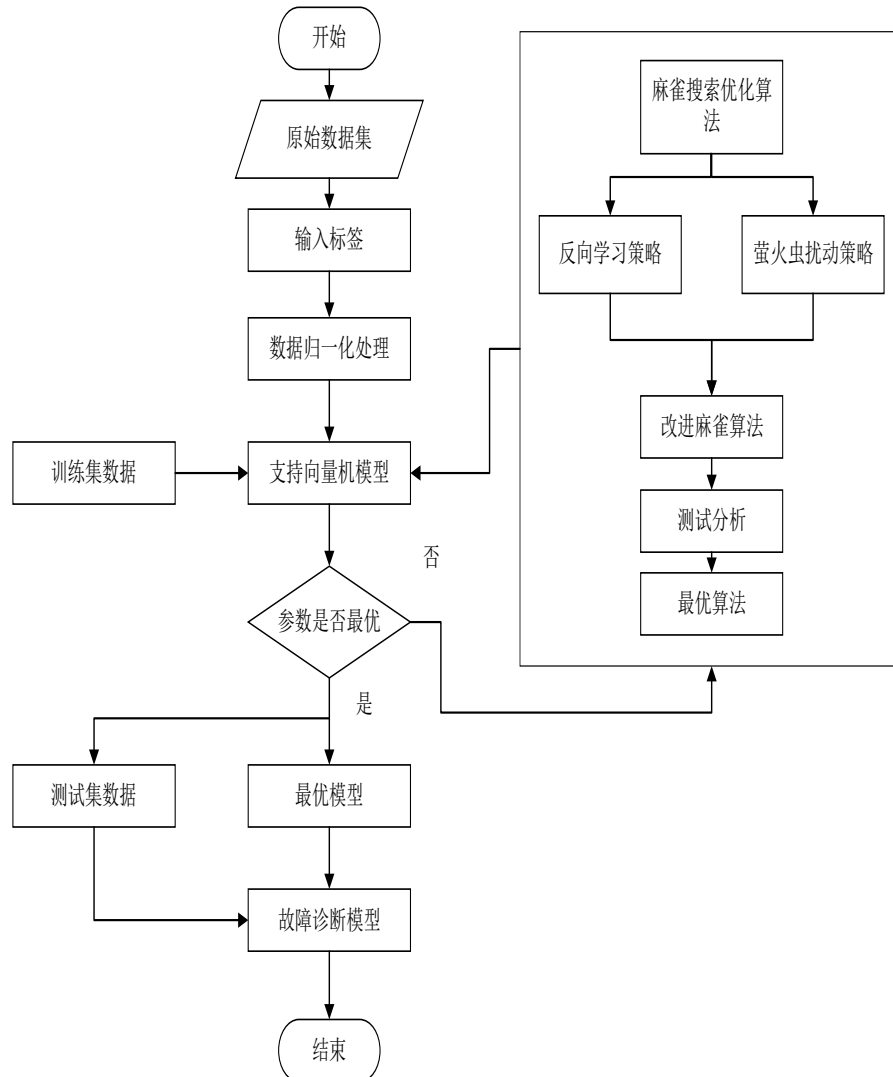


图 3.7 FA-ISSA-SVM 变压器故障诊断模型流程图

Fig. 3.7 Flow chart of FA-ISSA-SVM optimized transformer fault diagnosis model

## 3.6 变压器故障诊断的实例分析

### 3.6.1 样本数据收集与处理

本文选取辽宁省国家电网穆家换流站 500KV 实际测试采集到得历史变压器内部气体含量 371 组数据，如图 3.8 和 3.9 所示。首先进行数据的降噪除杂，将数据进行分类



标签同时进行可视化，如图 3.10 所示。通过可视化效果图我们可以明显看出各类数据中的异常数据，去掉异常、重复的数据，得到实际数据 354 组，本文将 354 组数据按 4:1 的比例分成训练集和测试集，其中训练集数据有 282 组，测试集数据有 72 组，具体样本的统计结果如下表 3.6 所示：



图 3.8 现场采集  
Fig. 3.8 Field acquisition



图 3.9 油色谱气体采集装置  
Fig. 3.9 Oil chromatographic gas acquisition device




图 3.10 数据可视化效果图  
Fig. 3.10 Data visualization

表 3.6 各类样本数据统计表  
Tab. 3.6 Statistical table of various sample data

状态	正常	中低温过热	高温过热	低能放电	高能放电
训练集	30	46	46	74	86
测试集	7	12	12	19	22
总计	37	58	58	93	108

3.6.2 变压器的故障诊断

将收集、处理好的数据输入故障诊断模型之中，与 SSA-SVM 模型进行对比分析。首先进行参数设置，种群的数目  $N$  设置为 20，最大迭代次数  $T$  设置为 150，惩罚因子  $C$  的取值范围为  $[0.01,10]$ ；核函数  $g$  的取值范围为  $[0.001,10]$ 。随机移动步长  $\omega$  为 0.5；

安全阈值  $R$  为 0.6; 发现者比例为 70%; 加入者比例为 30%; 警惕者随机比例为 20%。

分别将训练集数据输入到 SSA-SVM 和 FA-ISSA-SVM 模型进行训练, 训练结果如图 3.11 和图 3.12 所示。




图 3.11 SSA-SVM 模型训练集诊断结果

Fig. 3.11 Diagnosis results of SSA-SVM model training set




图 3.12 FA-ISSA-SVM 模型训练集诊断结构

Fig. 3.12 Diagnosis structure of FA-ISSA-SVM model training set

从训练集图 3.11-3.12 中可以看出在类别 1 和类别 4 的诊断准确率上, 改进后的模型更高, 但是其他类别由于数据值相对集中, 观察效果不是很好, 因此可以从算法的适应度曲线上加以区分; 图 3.13 和图 3.14 为算法的适应度曲线图。从图 3.13 可以看出

SSA-SVM 算法迭代速度缓慢, 迭代曲线呈现阶梯状, 说明在迭代过程中算法陷入到了局部最优且不能迅速的跳出局部最优, 在迭代了 65 次之后才达到收敛, 收敛的精度停留在  $1.48 \times 10^{-4}$  左右后达到平稳。相反图 3.14 可以看出 FA-ISSA-SVM 在迭代过程中, 迭代曲线光滑, 无明显阶梯状, 在迭代 27 次之后迅速收敛, 且收敛  $1.45 \times 10^{-4}$  后达到平稳。对比发现 FA-ISSA-SVM 模型无论是在速度还是在精度上都优于 SSA-SVM 模型。




图 3.13 SSA 算法适应度曲线图  
Fig. 3.13 Fitness curve of SSA algorithm




图 3.14 FA-ISSA 算法适应度曲线图  
Fig. 3.14 Fitness curve of FA-ISSA algorithm

为了验证本文改进的 FA-ISSA 的优秀性能, 现将 72 组测试集数据分别输入到 SSA-SVM、FA-ISSA-SVM、PSO-SVM、GWO-SVM、 $\beta$ -GWO-SVM 进行对比实验分

析，具体诊断结果如图 3.15-3.19 所示。




图 3.15 SSA-SVM 诊断结果  
Fig. 3.15 Diagnosis results of SSA-SVM




图 3.16 FA-ISSA-SVM 诊断结果  
Fig. 3.16 Diagnosis results of FA-ISSA-SVM




图 3.17 PSO-SVM 诊断结果图  
Fig. 3.17 Diagnosis results of PSO-SVM




图 3.18 GWO-SVM 诊断结果图  
Fig. 3.18 Diagnosis results of GEO-SVM




图 3.19  $\beta$ -GWO-SVM 诊断结果图  
Fig. 3.19 Diagnostic results of  $\beta$ -GMO-SVM

从图 3.15 可以看出 SSA-SVM 模型诊断结果中有 9 个错误分类，其中类别 1 没有

出现错误样本,在类别2中出现了2个错误分类,类别3出现了2个错误分类,类别4出现了3个错误分类,类别5出现了2个错误分类。总的来说并没有达到预期的效果,总体的诊断准确率为87.5%。图3.16采用的是FA-ISSA-SVM模型进行诊断,同样的测试集72组数据,该模型诊断与实际的故障相比出现了5个分类错误,类别1未出现错误分类,类别2中出现了1个错误;类别3出现了2个错误,类别4出现1个错误;类别5出现了1个错误,相较于没改之前有所提高。诊断的准确率为93.06%,与SSA-SVM相比该模型的诊断精度明显的提高。图3.17、3.18、3.19分别为其他优化算法对支持向量机优化的故障诊断模型诊断结果,通过图像可以看出它们在类别1上均出现了误判,同时它们针对放电故障的诊断准确率明显低于SSA-SVM和FA-ISSA-SVM模型,说明它们在两种放电故障的识别上效果较差,具体诊断准确率分别为PSO-SVM为86.11%;GWO-SVM为81.94%; $\beta$ -GWO-SVM为88.89%,均没有本文提出的模型诊断准确率高,且在正常状态下的诊断均发生了错误,整体的模型诊断效果并不好,诊断的准确率均低于90%。

为了证明本文提出的模型相对于其他传统模型更适合变压器的故障诊断,将72组测试样本分别带入到BPNN、多层感知机、KNN以及随机森林等传统的故障分类诊断模型中,从五种故障模式以及总的故障诊断准确率上进行详细的分析,具体诊断数据如表3.7所示。

表 3.7 模型对比诊断结果  
Tab. 3.7 Model comparison diagnosis results

实际状态	样本数目	准确率(正确/总数)				
		BPNN	多层感知机	KNN	随机森林	FA-ISSA-SVM
1	7	71.42% (5/7)	85.71% (6/7)	100% (7/7)	85.71% (6/7)	100% (7/7)
2	11	72.72% (8/11)	81.81% (9/11)	81.81% (9/11)	81.81% (9/11)	90.9% (10/11)
3	12	75% (9/12)	66.7% (8/12)	83.33% (10/12)	75% (9/12)	83.33% (10/12)
4	20	80% (16/20)	95% (19/20)	90% (18/20)	90% (18/20)	95% (19/20)
5	22	77.27% (17/22)	77.27% (17/22)	81.81% (18/22)	81.81% (18/22)	95.45% (21/22)
总计	72	76.38% (55/72)	81.94% (59/72)	86.11% (62/72)	83.33% (60/72)	93.06% (67/72)

从上表中可以看出BPNN、多层感知机、KNN以及随机森林模型的故障分类准确率分别为76.38%、81.94%、86.11%和83.33%;而FA-ISSA-SVM诊断准确率为93.06%,

虽然相比于训练集上的准确率有所降低，但是明显高于其他几种诊断方法，说明了本文提出的诊断模型在变压器故障诊断领域诊断精度高，效果好。

### 3.7 本章小结

本章根据变压器故障数据类型繁多的特点引进了 SVM 模型进行故障分类，针对 SVM 参数难以选择的缺点，采用 FA-ISSA 进行参数寻优。首先对 SSA 进行了改进，引入了反向学习策略来提高初始麻雀种群的质量，同时采用 FA 来对各类麻雀位置进行扰动，解决算法易陷入到局部最优的问题；之后利用 Matlab 常用的测试函数对改进算法进行了仿真测试实验，结果证明本文的改进方法有效的提升了算法的性能；最后构建了基于 FA-ISSA-SVM 的变压器故障诊断模型；通过对变压器实际数据的处理、划分、输入以及对比分析，证明了改进后的算法在实际案例分析中仍然具有更好、更高的性能，更适合变压器故障诊断领域。

## 第 4 章 基于提升极限学习机的变压器故障预测

在第三章之中利用反向学习策略和萤火虫扰动策略改进了麻雀算法，改进后的算法优化了支持向量机参数，通过测试分析证明了改进后算法的优秀性能，在此基础上建立变压器故障诊断模型，证明了油中溶解气体含量在变压器故障诊断领域的重要性；因此本章以以往变压器油中溶解特征气体含量为基础来预测未来特征气体的含量，构建了改进麻雀算法提升极限学习机的油中溶解气体预测模型，最后将预测模型与第三章建立的故障诊断模型相结合，从预测类型精度和预测时间精度两方面构建故障预测模型；通过实例分析证明，该模型具有很好的预测准确度。

### 4.1 变压器故障预测方法

油中溶解气体含量作为变压器故障诊断的重要指标，在以往的研究中起着非常重要的作用<sup>[46]</sup>。变压器在发生故障之前各种气体在油中的含量是随时间发生缓慢的变化，因此基于变压器油中溶解气体含量的历史变化数据，对未来时间段油中气体含量进行预测，进而推测出未来可能发生的故障是完全可以实现的<sup>[47-49]</sup>。

随着机器学习、深度学习算法的兴起，油中溶解气体含量已经逐渐成为变压器故障预测领域的研究热门。各种智能算法也相继被应用到该领域中，目前主要还是依据对溶解特征气体含量的预测来实现对变压器故障的预测，其中主流的预测方法有：灰色理论、时间序列分析、极限学习机和组合预测的方法<sup>[50]</sup>。具体算法及特点如表 4.1 所示。极限学习机作为一种前馈的神经网络，其优秀的回归特性深受广大研究学者的喜欢，从表 4.1 中也可以看出，极限学习机预测精度好，参数调整难度低的特性在变压器溶解气体含量的预测方面体现的尤为明显<sup>[51-53]</sup>。因此本文采用极限学习机模型来对变压器内部的特征气体含量进行预测，从而实现对于变压器未来故障的精准预测。

表 4.1 变压器预测算法比较  
Tab. 4.1 Comparison of transformer prediction algorithms

算法	特点
灰色理论	能够处理无规则数据，通用性强，但是缺乏足够的基础理论支持，不适宜长期预测。
时间序列	适合长期的气体含量预测方法，但是在预测精度上相对较低
极限学习机	属于神经网络，预测精度较高；但是参数选择较难，人为干预多
组合预测方法	预测精度很高，但算法融合过度会导致过拟合

极限学习机 (Extreme Learning Machine, ELM) 是一种新型的单隐层前馈神经网络算法。近年来随着神经网络的迅速崛起, 应用于变压器故障预测领域的神经网络算法也越来越多, 单隐层神经网络因为其非常好的学习能力, 一经应用就迅速成为了研究热点, 该算法工作具有学习能力强、学习速度快、泛化能力强等优点<sup>[54-57]</sup>。

ELM 作为数理基础的算法其理论背景如下:

#### (1) 插值定理

插值定理规定: 任意  $M$  个完全不同的随机样本  $(x_i, n_i) \in R^d \times R^m \quad i=1, 2, \dots, M$ , 有  $Q$  个隐藏层的神经元的 SLFNs, 则可以用如下方式来表示:

$$\sum_{i=1}^Q \alpha_i g_i(x_j) = \sum_{i=1}^Q \alpha_i G(\alpha_i, b_i, x_j) = o_j \quad j=1, 2, \dots, M \quad (4.1)$$

通过该 SLFNs 在无均值误差的逼近样本的过程中, 还要满足  $\sum_{j=1}^Q \|o_j - t_j\| = 0$ , 那么就一定存在  $(a_i, b_i)$  和  $\alpha_i$  满足:

$$\sum_{i=1}^Q \alpha_i G(\alpha_i, b_i, x_j) = t_j \quad j=1, 2, \dots, M \quad (4.2)$$

令  $\sum_{i=1}^Q \alpha_i G(\alpha_i, b_i, x_j) = H$ , 则可以将上式写成:

$$H\alpha = T \quad (4.3)$$

其中  $H$  为 SLFN 的隐含层输出矩阵, 如下式:

$$H = \begin{bmatrix} h(x_1) \\ \dots \\ h(x_M) \end{bmatrix} = \begin{bmatrix} G(a_1, b_1, x_1) & \dots & G(a_Q, b_Q, x_1) \\ \dots & \dots & \dots \\ G(a_1, b_1, x_M) & \dots & G(a_Q, b_Q, x_M) \end{bmatrix}_{M \times Q} \quad (4.4)$$

$$\text{其中 } \alpha = \begin{bmatrix} \alpha_1^T \\ \dots \\ \alpha_q^T \end{bmatrix}_{Q \times M}, \quad T = \begin{bmatrix} t_1^T \\ \dots \\ t_q^T \end{bmatrix}_{M \times m}$$

定理 4.1: 规定一个有  $N$  个样本的数据集  $(x_i, n_i) \in R^d \times R^m$  和一个任意小的整数  $\gamma > 0$ , 那么总会存在一个含有  $M$  ( $M < N$ ) 个隐含层节点的 SLFNs, 激活函数  $g$ ; 在给定的空间内无限可微, 且参数  $\{a_i, b_i\}_{i=1}^M$  在给定的空间内随机生成, 那么总会存在  $\|H_{N \times M} \alpha_{M \times m} - T_{N \times m}\| < \gamma$ 。

但是由于插值定理具有一定的震荡性, 导致算法的泛化能力下降, 基于此缺点我国学者黄广斌等研究了隐含层神经元的逼近能力。

假设存在  $F^2(X)$  为  $X$  在  $n$  维欧几里得空间上的函数  $g$  的空间, 则函数  $g$  一定会满足  $\int_x |g(x)|^2 dx < \infty$ 。对于任意的  $u, v \in F^2(X)$ , 则  $\langle u, v \rangle$  内积为:

$$\langle u, v \rangle = \int_x u(x)v(x)dx \quad (4.5)$$



根据函数范数的运算定义, 则用来描述神经网络的目标函数  $f$  和模型函数  $f_n$  之间的距离的公式为:

$$\|f_n - f\| = \left[ \int_x |f_n(x) - f(x)|^2 dx \right]^{\frac{1}{2}} \quad (4.6)$$

定义引理 4.2, 给定一个函数  $g(x)$ , 若  $g(x)$  是一个多项式函数, 则对于任意的  $q \in [1, \infty)$ ,  $\text{span}\{g(a^*x + b) : (a, b) \in R^d \times R\}$  在空间内是紧致的。

定义引理 4.3,  $R^d$  为一个有界的可积连续函数, 同时  $\int_R^d L(x)dx \neq 0$ , 同样可以得出对于任意的  $q \in [1, \infty)$ ,  $\text{span}\{g(L((x - a)/b)) : (a, b) \in R^d \times R^*$  在空间内也是紧致的。

通过上面两个引理可以看出, 对于极限学习机中的参数  $(a_i, b_i)$ , 通过训练和调整可以逼近任意函数, 但是这只是简单的对激活函数为增函数或者是 RBF 函数的一种广义逼近的解释, 并没有就如何得到最优参数给出相应的说明, 因此很多学者针对这两个函数参数的寻优做出了大量的研究, 相应的算法也被提出, 本文正是在此基础上, 选用第三章改进的麻雀算法对其进行参数寻优, 使得极限学习机模型更加适合变压器溶解气体含量的预测。

## (2) ELM 模型

根据式 (4.1) 和式 (4.4) 可知, SLFNs 中的输入层和隐含层之间的偏置向量和隐含层和输出层之间的权重向量需要确定。对于连接权重向量  $\alpha$  可以通过  $H\alpha = T$  的最小二乘解来确定  $\alpha^*$  的取值:

$$\|H\alpha^* - T\| = \min \|H\alpha - T\| \quad (4.7)$$

若训练样本  $N$  和隐含层神经元数量  $L$  相等, 根据定理 4.1, 隐含层的输出矩阵为一个方阵则此时存在相等的在  $a_i, b_i, \alpha_i$  使得  $H\alpha = T$  成立; 但是在大多数的情况之下是不相等。此时, 对于上述的线性系统的最小二乘解就会变为:

$$\alpha^* = H^+T \quad (4.8)$$

其中  $H^+$  是  $H$  的 Moore-Penrose 广义逆矩阵。

基于上述的描述 ELM 算法可以简单地描述为以下几步:

(1) 给定训练集  $(x_i, n_i) \in R^d \times R^m \ i = 1, 2, \dots, N$ , 一个隐含层函数  $G(a_i, b_i, \alpha_i)$  和隐含层神经元数  $L$ 。

(2) 随机生成隐含层的参数  $(a_i, b_i) \ i = 1, 2, \dots, L$ ;

(3) 计算隐含层神经元的输出矩阵  $H$ ;

(4) 计算隐含层与输出层之间的连接权重向量  $\alpha^* = H^+T$ 。

(5) 生成算法

ELM 的理论结构图, 如图 4.1 所示:




图 4.1 极限学习机结构

Fig. 4.1 Structure of extreme learning machine

从以上陈述可以得出极限学习机算法的优点:

- (1) 训练速度快、只需要训练一次即可, 不需要反复的训练。
- (2) 算法泛化性非常强, 不容易陷入局部最优。

极限学习机的缺点:

- (3) 作为神经网络, 依然存在过拟合现象。
- (4) 输入权值、隐含层偏置的随机选择导致算法针对到某一特殊问题时, 效果并不是很好。

通过 ELM 的理论知识、网络结构图以及优缺点可以清楚的看出, 在 ELM 网络中, 连接权重和偏置的选择对于改善模型的性能具有决定性作用, 若能够根据不同的输入数据集特点, 选择最优的偏置与权重, 算法模型的性能也必将更加优秀。因此本文正是基于此, 选择 FA-ISSA 来对这两个参数进行寻优, 进一步提高算法的预测准确率。

## 4.2 变压器溶解气体含量预测模型的构建

本章将通过 FA-ISSA 算法优秀的全局搜索能力, 来寻找 ELM 中更适合变压器气体含量预测的连接权重和偏置这两个参数值, 提高极限学习机模型的预测准确率, 搭建变压器溶解气体含量预测模型。

### 4.2.1 特征量的选取与处理

本文将  $H_2$ 、 $CH_4$ 、 $C_2H_4$ 、 $C_2H_6$ 、 $C_2H_2$  这五种气体的含量作为 FA-ISSA-ELM 模型

的特征数据进行输入。由于五种不同的气体在油液中的含量有些差异化，故需要对其进行归一化处理。归一化的公式如下：

$$X_{i,j}^1 = \frac{X_{i,j}}{\sum_{k=1}^5 X_{i,k}} \quad (4.9)$$

其中  $X_{i,j}$  表示归一化后的特征气体的值； $X_{i,j}^1$  表示原来的特征气体含量值。

#### 4.2.2 变压器油中溶解气体含量预测模型

本章采用提升极限学习机作为训练和测试的模型，误差标准选择均方根误差、平均绝对误差和平均绝对百分比误差这三个变量作为预测模型预测精度的评价标准。隐含层的激活函数选择 Sigmoid 函数。选择经过 FA-ISSA 寻优后的输入层和隐含层间的连接权重和隐含层神经元的偏置作为初始网络权重和偏置。将前几个时刻的值作为输入，来预测当前时刻的值。也就是 1 到  $n$  时刻的值为输入， $n+1$  时刻的值为输出，然后 2 到  $n+1$  时刻的值为输入， $n+2$  时刻的值为输出。根据参数选取结果建立模型，具体的建模流程图如图 4.2 所示。

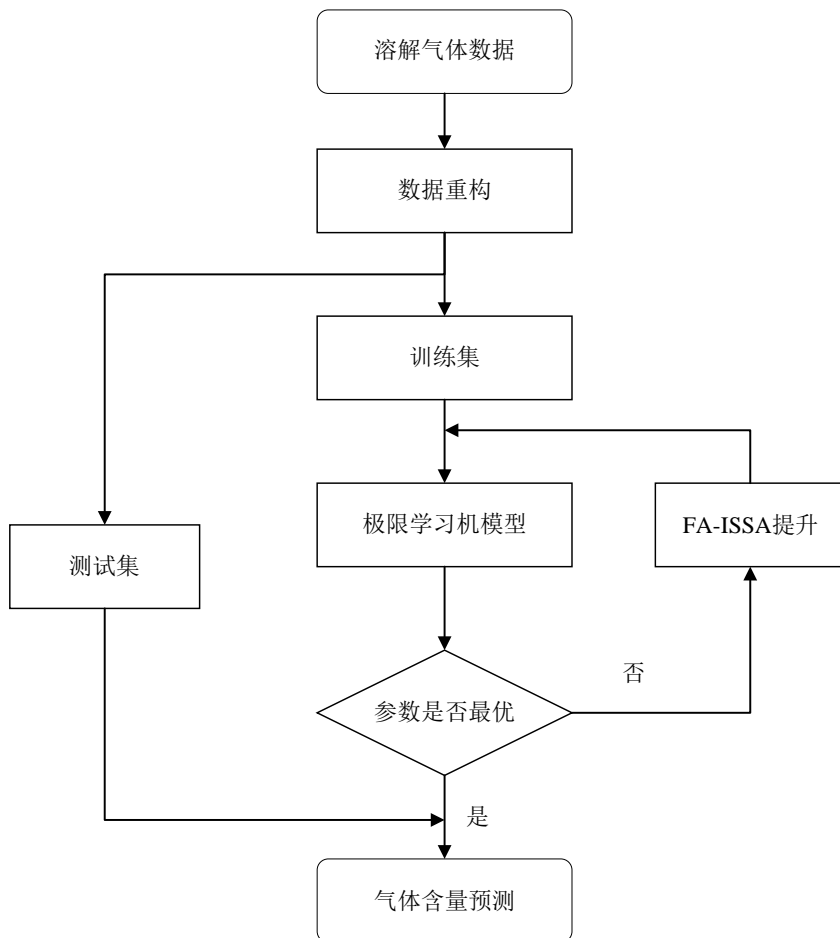


图 4.2 变压器溶解气体含量预测模型流程图

Fig. 4.2 Flow chart of transformer dissolved gas content prediction model

### 4.3 变压器油中气体含量预测实例分析

#### 4.3.1 样本收集与处理

从实际现场收集到实际气体含量数据 99 组，按照 3: 1 的比例划分成训练集和测试集，其中训练集有 76 组，测试集有 23 组。部分数据如表 4.2 所示。

表 4.2 部分实测数据  
Tab. 4.2 Part of measured data

气体 序号	H <sub>2</sub>	CH <sub>4</sub>	C <sub>2</sub> H <sub>6</sub>	C <sub>2</sub> H <sub>4</sub>	C <sub>2</sub> H <sub>2</sub>
1	14.67	3.68	10.54	2.71	0.2
2	7.5	5.7	3.4	2.6	3.2
3	19	10	7.9	9.5	8.5
4	166.6	28.31	6.72	12.4	0.3
5	70.4	69.5	28.9	241.2	0.4
6	31.7	40.3	8.7	107	4.5
.....	.....	.....	.....	.....	.....
88	66.4	23.5	9.5	66.7	5.2
89	56.7	78.1	19.4	28.9	3.4
90	30.2	16.8	22.1	40.56	8.7
91	24.32	16.36	1.67	30.18	27.47
92	30.409	8.141	0.721	16.003	44.725
93	39.183	24.489	18.367	11.428	6.530
94	23.023	12.004	10.059	12	61.82
95	27	90	42	63	0.2
96	29	7.52	5.5	14.8	5.4
97	29.9	34.6	5.6	70	1.2
98	30	110	137	52	22.3
99	30.40	8.14	0.72	16.00	44.72

### 4.3.2 变压器溶解气体含量预测

本文将对五种特征气体含量分别进行预测含量。首先进行模型参数的设置，种群的初始数量为 50，最大迭代次数 500，搜索空间的上限为 500，下限为-500，维度为 30。发现者比例为 70%；加入者比例为 30%；警惕者比例为 20%；然后将 76 组训练集数据带入进行模型的训练，训练效果良好，接下来分别对物种特征气体进行测试集预测。

#### (1) $H_2$ 含量预测

现将  $H_2$  测试集中的 23 组数据分别代入到 ELM 和 FA-ISSA-ELM 模型中进行预测，具体预测结果如图 4.3、4.4 所示。




图 4.3 ELM 预测图  
Fig. 4.3 ELM prediction chart




图 4.4 FA-ISSA-ELM 预测图  
Fig.4.4 FA-ISSA-ELM prediction chart

从上述的图 4.3、4.4 中可以看出 ELM 模型在前期的拟合程度相较于 FA-ISSA-ELM 没有太大的区别，但是随天数的增加拟合的效果越来越差，误差也越来越大，拟合曲线的差别越来越明显，说明未进行提升的模型鲁棒性较差。从图 4.4 可以清晰地看出，提升过后的预测模型拟合程度要明显高于未提升之前的模型，尤其是在后期的预测上，曲线贴近程度明显更好，误差明显降低，准确率明显提高。

为了更加直观的看出提升后模型的优秀性能，进行了对比试验，随机抽取五天数据分别带入 FA-ISSA-ELM 以及传统的  $M(1, 1)$  模型、ARIMA 模型、BPNN 进行预测值比较分析，具体数值如表 4.3 所示。同时将四种模型具体预测的均方根误差、平均绝对误差和平均绝对百分比误差也进行对比分析，具体数值如表 4.4 所示

表 4.3 真实值与预测值对比图

Tab. 4.3 Comparison between real value and predicted value

模型 时间	实际值	GM (1, 1)	ARIMA	BPNN	FA-ISSA-ELM
3月1日	56.001	55.283	55.196	55.321	56.074
3月15日	56.403	55.952	55.567	55.214	55.977
4月1日	56.98	56.31	56.22	56.49	56.98
4月15日	57.003	56.898	56.884	57.681	57.402
5月1日	57.98	57.21	57.02	57.68	57.79

表 4.4 预测衡量指标

Tab. 4.4 Forecast indicators

模型 标准	GM (1, 1)	ARIMA	BPNN	FA-ISSA-ELM
均方根误差	1.007	0.952	1.089	0.647
平均绝对误差	0.766	0.658	0.627	0.528
平均绝对百分比 误差	1.450%	1.234%	1.389%	1.043%

通过对实际数据的具体预测数值以及衡量指标的对比分析可知，在对  $H_2$  实际的预测值上 FA-ISSA-ELM 明显比其他三种模型要精确；而在其余三种指标的数据值上 FA-ISSA-ELM 模型依旧优于其他三种模型，验证了本文所构建模型的优秀性能。

通过对  $H_2$  含量的预测，已经证明了本文建立的模型在变压器溶解气体含量的预测的优良性能，但是不排除模型对单一气体预测准确度高，因此，接下来对另外四种特征气体进行预测。

## (2) $CH_4$ 含量预测

同样的取样本数据中五组数据来对  $CH_4$  进行预测，将预测值与实际值进行比较，各模型的预测结果以及误差对比如表 4.5 所示。

表 4.5 CH<sub>4</sub> 实际值与预测值比较  
Tab. 4.5 CH<sub>4</sub> Comparison of actual and predicted values

模型 时间	实际值	GM (1, 1)	ARIMA	BPNN	FA-ISSA-ELM
3月1号	38.13	38.79	39.06	38.88	38.54
3月15号	35.64	36.84	35.97	35.88	35.64
4月1号	44.25	42.26	43.06	45.72	45.60
4月15号	43.83	41.33	42.89	43.01	43.69
5月1号	60.013	52.091	55.896	54.667	58.431
均方根误差		11.353	7.672	9.856	2.148
平均绝对误差		6.869	5.227	4.578	1.058
平均绝对百分比误差		11.172%	7.356%	8.572%	2.241%

由表 4.5 实际数据值、四种预测模型的预测值以及三种特征量值得比较可知,拟合最好的是 FA-ISSA-SVM 预测模型,其误差为 2.241%,平均绝对误差值为 1.058;均方根误差为 2.148,均为四种模型中的最低。

### (3) C<sub>2</sub>H<sub>2</sub> 含量预测

四种模型预测结果及误差对比如表 4.6 所示。

4.6 C<sub>2</sub>H<sub>2</sub> 实际值与预测值比较  
Tab. 4.6 C<sub>2</sub>H<sub>2</sub> Comparison of actual and predicted values

模型 时间	实际值	GM (1, 1)	ARIMA	BPNN	FA-ISSA-ELM
3月1号	5.4	5.21	5.36	5.53	5.37
3月15号	5.8	5.49	5.62	5.36	5.74
4月1号	4.9	4.69	4.56	4.76	4.86
4月15号	6.63	6.55	6.74	6.76	6.63
5月1号	6	5.75	5.84	5.56	6.13
均方根误差		0.815	0.945	1.002	0.148
平均绝对误差		0.801	0.798	0.954	0.126
平均绝对百分比误差		12.505%	11.257%	10.687%	2.168%

由表 4.6 实际数据值、四种预测模型的预测值以及三种特征量值得比较可知,拟合最好的是 FA-ISSA-SVM 预测模型,其误差为 2.168%,平均绝对误差值为 0.126;均方根误差为 0.148,仍为四种模型中的最低。

(4)  $C_2H_6$  含量预测

四种模型预测结果及误差对比如表 4.7 所示

表 4.7  $C_2H_6$  实际值与预测值比较  
Tab. 4.7  $C_2H_6$  Comparison of actual and predicted values

模型 时间	实际值	GM (1, 1)	ARIMA	BPNN	FA-ISSA-ELM
3月1日	13	13.21	13.52	13.40	13.01
3月15日	12.14	11.19	11.56	11.68	11.75
4月1日	10.91	10.46	10.66	10.77	10.86
4月15日	14.01	14.65	14.45	14.48	14.22
5月1日	15.124	15.229	15.342	15.562	15.052
均方根误差		0.372	0.485	0.623	0.290
平均绝对误差		0.287	0.378	0.465	0.223
平均绝对百分比误差		2.221%	3.426%	3.985%	1.714%

由表 4.7 实际数据值、四种预测模型的预测值以及三种特征量值得比较可知, 拟合最好的是 FA-ISSA-SVM 预测模型, 其误差为 1.714%, 平均绝对误差值为 0.223; 均方根误差为 0.290, 依旧为四种模型中的最低。

(5)  $C_2H_4$  含量预测

四种模型预测结果及误差对比如表 4.8 所示

表 4.8  $C_2H_4$  实际值与预测值比较  
Tab. 4.8  $C_2H_4$  Comparison of actual and predicted values

模型 时间	实际值	GM (1, 1)	ARIMA	BPNN	FA-ISSA-ELM
3月1日	52.6	53.76	54.23	53.66	52.71
3月15日	51.8	53.16	52.96	51.31	52.09
4月1日	48.90	50.03	49.23	48.03	49.64
4月15日	55.41	53.61	55.92	56.16	54.91
5月1日	61.88	60.55	60.98	62.54	61.46
均方根误差		1.352	1.653	2.348	0.853
平均绝对误差		1.138	1.342	2.056	0.755
平均绝对百分比误差		2.053%	2.874%	5.168%	1.325%

由表 4.8 实际数据值、四种预测模型的预测值以及三种特征量值得比较可



知, 拟合最好的是 FA-ISSA-SVM 预测模型, 其误差为 1.325%, 平均绝对误差值为 0.755; 均方根误差为 0.853, 仍为四种模型中的最低。

训练集上其他特征气体含量预测对比图如下图 4.5-4.8 所示:




图 4.5 CH<sub>4</sub> 预测图  
Fig. 4.5 CH<sub>4</sub> prediction chart




图 4.7 C<sub>2</sub>H<sub>2</sub> 预测图  
Fig. 4.7 C<sub>2</sub>H<sub>2</sub> prediction chart




图 4.6 C<sub>2</sub>H<sub>4</sub> 预测图  
Fig. 4.6 C<sub>2</sub>H<sub>4</sub> prediction chart




图 4.8 C<sub>2</sub>H<sub>6</sub> 预测图  
Fig. 4.8 C<sub>2</sub>H<sub>6</sub> prediction chart

## 4.4 变压器的故障预测

本节将第三章和第四章所建立的模型进行结合, 构建了变压器故障预测模型, 将收集到的实际数据样本输入到模型中去, 从预测时间和预测精度两种角度对模型的性能进行测试。通过对测试结果的分析, 来阐述该模型在实际工程中的应用价值。

基于第三章和第四章建立的主要模型, 建立了基于油中溶解特征气体含量的变压器故障预测模型。通过提升极限学习机的油中溶解气体含量预测模型来对未来油中的特征气体含量进行预测, 将预测后的含量输入到 FA-ISSA-SVM 变压器故障诊断模型进行故障诊断, 从而实现对故障的预测。具体的模型预测流程如图所示:

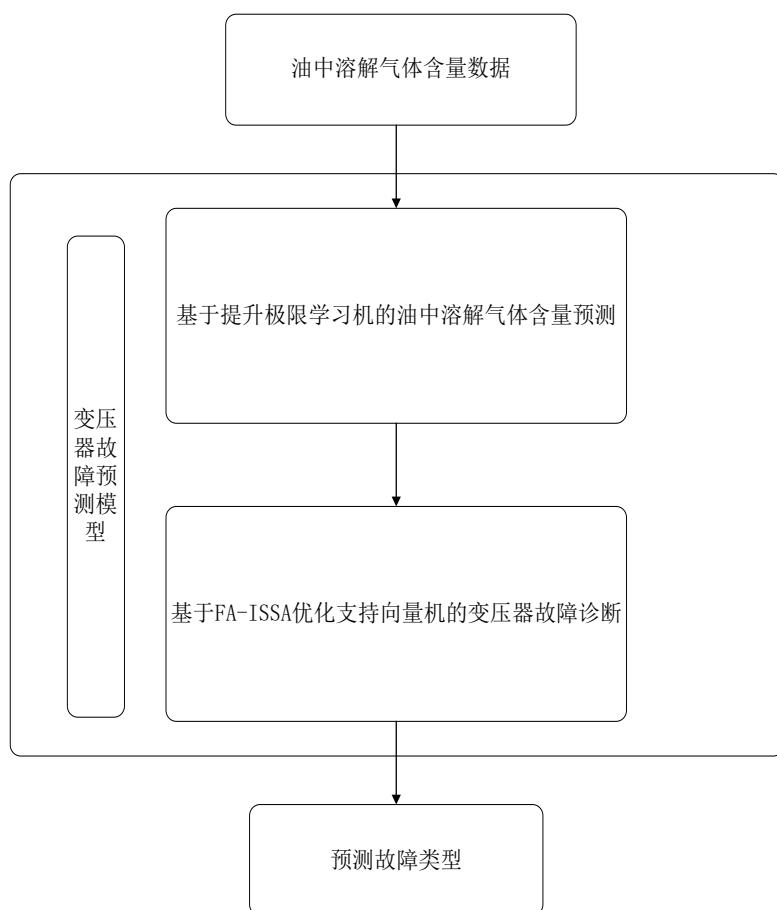


图 4.9 变压器故障预测流程图

Fig.4.9 Flow chart of transformer fault prediction

#### 4.4.1 实例分析

基于辽宁省国家电网公开网站以及相关文献收集到已经明确故障的实际数据 200 组，选取五种类型各 40 组进行模型的验证。从实际的工程情况出发，提出了两种评判标准：一、预测的时间精度；二、故障的预测精度

##### 一、预测的时间精度

时间精度是指通过模型来预测故障发生的可能时间，由于实际的情况的不相同，将误差分为三种超前、正常、滞后。具体的时间划分方式如表 4.9 所示：

表 4.9 时间预测精度划分表

Tab. 4.9 Time prediction accuracy division

误差类型	时间	含义
滞后	>20	实际故障发生在预测时间 20 天前
正常	-20-20	实际故障发生在预测区间内
超前	<-20	实际故障发生在预测时间的后 20 天

## 二、故障的预测精度

将故障预测的准确率进行统计，分为三种；一、故障类型预测正确（精准预测）；二、故障预测正确但类型错误（半精准预测）；三、故障预测错误（错误预测）。

表 4.10 故障预测类型精度的划分  
Tab. 4.10 Classification of fault prediction type accuracy

误差类型	含义
精准预测	故障类型预测准确或者准确判断正常状态
半精确预测	判断出故障但是故障类型预测错误
错误预测	故障样本未预测出发生故障或者正常状态判断发生了故障

以上述的两个指标为标准，在实际收集到的 200 组故障数据中抽取 10 组已知故障的变压器油中溶解气体的历史数据进行故障预测。具体预测结果如表 4.11 所示。

表 4.11 部分故障预测结果  
Tab. 4.11 Partial fault prediction results

故障实际发生时间	预测时间	实际故障类型	预测类型
2018.3.15	2018.3.10	高温过热	高温过热
2018.4.30	2018.5.15	低能放电	低能放电
2018.7.25	2018.8.26 <sup>*</sup>	高能放电	高能放电
2018.12.23	2018.1.10	中低温过热	中低温过热
2019.5.29	2019.6.3	高温过热	高温过热
2020.1.16	2020.1.3	低能放电	高能放电 <sup>*</sup>
2020.6.25	2020.6.28	正常	正常
2020.11.6	2020.10.26	中低温过热	中低温过热
2020.12.13	2020.11.10 <sup>*</sup>	低能放电	低能放电
2021.4.25	2021.5.11	高能放电	高能放电

注：‘\*’ 表示为预测错误

从表中部分预测结果可以看出,在时间精度上出现了 2 个错误;类型精度上出现了 1 个错误,整体符合预期猜想。接下来对所有的 200 组样本进行预测验证,具体结果整理为如下饼状图 4.10、4.11 所示。




图 4.10 时间预测精度结果  
Fig. 4.10 Time prediction accuracy results




图 4.11 故障类型预测精度结果  
Fig. 4.11 Fault type prediction accuracy results

针对图 4.10 分析可知,有 89%的故障样本可以在期望的时间被预测出来,而大约 7%的故障样本的实际故障发生时间晚于预测所发生的时间段;4%的故障样本实际发生的时间早于预测所发生的时间。

图 4.11 显示在所有的样本预测精度上面,预测精准的占据了 88.7%;而在故障类型的判别上错误率仍然有 9.6%;其余的 1.7%故障完全判断错误,即对模型的过热故障可能诊断为放电故障或者将正常状态诊断为了故障状态。通过上述分析证明了本文提出的变压器故障预测模型具有很好的故障预测性能。

## 4.5 本章小结

本章是将第三章中 FA-ISSA 与 ELM 进行结合, 搭建变压器油中溶解气体含量的预测模型。以特征气体  $H_2$ 、 $CH_4$ 、 $C_2H_2$ 、 $C_2H_4$ 、 $C_2H_6$  的含量作为输入, 利用 FA-ISSA 来 ELM 模型的预测精度。以均方根误差、平均绝对误差值、平均绝对百分比误差以及预测含量作为模型的比较标准; 通过对五种气体预测实例, 证明了改进麻雀算法可以很好的优化极限学习机模型; 对实际采集 23 组数据进行预测并于常见的三种预测模型进行对比, 结果显示本章建立的 FA-ISSA-ELM 模型在变压器油中溶解气体含量领域具有很好的效果; 随后搭建了气体含量预测模型和诊断模型相结合的变压器故障预测模型, 通过对 200 组实际数据的时间精度和类型精度的预测, 证明了本文提出的故障预测模型, 具有良好的预测精度, 可以投入到实际的变压器监测系统之中。

## 第5章 结论与展望

### 5.1 结论

电力变压器作为电力系统的核心部件，它的安全稳定运行，关系着整个电力系统的稳定。由于变压器内部零件众多及工况复杂繁琐，导致变压器的故障类型繁杂，如何对这些潜在故障进行精准预测和快速诊断，对于变压器的智能检修具有很大的帮助，可以避免引起电力行业的损失。本文具体的研究结论如下：

(1) 首先通过对变压器结构与原理的研究，发现变压器故障主要分为热故障、电故障和机械故障；这些故障最终在变压器内部的表现形式主要体现在内部绝缘系统分解为产生各种特征气体含量的变化上，其中主要有  $H_2$ 、 $CH_4$ 、 $C_2H_2$ 、 $C_2H_4$ 、 $C_2H_6$  这五种气体，同时针对三种不同的故障类型产生的过程中五种气体含量及气体种类的变化，变压器故障可以归纳为主要的五类：正常、中低温过热、高温过热、低能放电、高能放电。

(2) 考虑到变压器内部气体含量之间的密切联系，构建了 14 种特征指标，作为诊断模型的输入量，解决了单一含量指标使得诊断效率低的问题；针对传统单一诊断方法诊断准确率低的缺点，提出了基于 FA-ISSA-SVM 的变压器故障诊断模型；通过对 SSA 的改进，实现了对 SVM 的寻优，形成最优诊断模型；仿真测试结果显示构建的 FA-ISSA-SVM 模型具有很高性能；实例分析表明，在与其他优化方法的对比试验中，FA-ISSA 的优化性能明显好其他优化方法；将实际测得 372 组变压器气体数据，进行输入诊断，诊断准确率高达 93.06%，明显高于传统 BPNN、多层感知机、KNN 和随机森林等诊断模型，符合预期设想。

(3) 基于提升极限学习机的变压器油中气体含量预测模型，在构建好的模型和实际 99 组采集到的数据的训练调优之下，对比了 GM(1, 1)、ARIMA 和 BPNN 三种预测模型，实验结果证明该模型具有更低的均方根误差、平均绝对误差、平均绝对百分比误差；同时对含量预测精度也明显较高。在此基础上搭建了提升极限学习机结合 FA-ISSA-SVM 的变压器故障预测模型。200 组实例分析表明，在时间精度上预测准确率高达 89%，在类型精度上准确率高达 88.7%，符合预期的设想。此方法可以为变压器的运维提供很好的帮助。

## 5.2 展望

本文主要针对换流站变压器的故障诊断以及故障预测做了详细的研究,同时针对研究过程中发现的问题提出了基于 FA-ISSA-SVM 的故障诊断模型以及基于提升极限学习机的溶解气体含量预测模型,通过实验以及实际采集数据的研究分析,结果验证了所提模型具有优秀性能;最后将预测模型与故障模型相结合构建了变压器故障预测模型,通过实例分析,验证了模型预测精度高,可以投入到电力维护系统之中。但是本文在对数据的预处理方面做的相对较为粗糙,没有更好的挖掘数据的全部特征,因此对于数据的预处理方面还有待进一步的研究,如何通过数据挖掘来进一步提取数据之间的特征关系,从而提高诊断和预测精度,还有待进一步研究。同时鉴于实际条件的限制,本文只是单纯的以溶解气体含量作为特征进行分析。但是变压器内部复杂,电磁,震动故障也偶有发生,如何将这些故障信息进行融合,更加全面的对变压器进行诊断和预测,有待于其他的研究者做更深层次的研究。

## 参考文献

- [1] 沈杰. 基于堆栈自编码神经网络的自适应分类算法在变压器故障诊断中的应用[D]. 兰州: 兰州理工大学, 2020.
- [2] 赵丹. 基于频响曲线特征的变压器绕组变形诊断方法研究[D]. 西安: 西安理工大学, 2020.
- [3] 郭云. 基于深度学习的电网故障诊断[D]. 北京: 华北电力大学, 2020.
- [4] Wang Q W, Shi N, Shi R, et al. A Power Transformer Fault Diagnosis Method Based on Random Vector Functional-Link Neural Network[J]. Mathematical Problems in Engineering, 2021, 1934: 112-128.
- [5] 董新华. 基于多源信息融合的配电网故障诊断方法[D]. 山东: 山东科技大学, 2020.
- [6] 翟玉晓. 基于深度网络的大型变压器故障诊断技术研究[D]. 兰州: 兰州理工大学, 2020.
- [7] Wang T B, Zhang L, Wu Y F. Research on transformer fault diagnosis based on GWO-RF algorithm[J]. Journal of Physics: Conference Series, 2021, 1952: 17-26(3).
- [8] 刘洋. 电力变压器电气故障诊断与剩余寿命预测技术研究[D]. 沈阳: 沈阳工业大学, 2020.
- [9] 张思捷. 电力变压器状态评价与故障诊断技术研究[D]. 哈尔滨: 哈尔滨工业大学, 2020.
- [10] Zhou Y H, Yang X H, Tao L Y, et al. Transformer Fault Diagnosis Model Based on Improved Gray Wolf Optimizer and Probabilistic Neural Network[J]. Energies, 2021, 14(11): 1090-1097.
- [11] Fan C, Ku H, Huang Y C, et al. Power Electric Transformer Fault Diagnosis Based on Infrared Thermal Images Using Wasserstein Generative Adversarial Networks and Deep Learning Classifier[J]. Electronics, 2021, 10(10): 150-157.
- [12] 闫荣格, 董正予, 焦佩林, 等. 基于振动分析的变压器铁心故障诊断[J]. 电工电能新技术, 2021, 40(01): 55-60.
- [13] 罗颖婷, 许海林, 林春耀, 等. 基于集对分析的变压器故障案例检索方法[J]. 高压电器, 2021, 57(01): 182-188.
- [14] 黄新波, 马玉涛, 朱永灿. 基于信息融合和 M-RVM 的变压器故障诊断方法[J]. 电力自动化设备, 2020, 40(12): 218-225.
- [15] Zou J Y, Liang Q, Xu X M, et al. Transformer Fault Diagnosis Based on Optimized CPSO-BP Neural Network[J]. IOP Conference Series: Earth and Environmental Science, 2021, 781(4): 200-217.
- [16] 吴瞻宇, 董明, 王健一, 等. 基于模糊关联规则挖掘的电力变压器故障诊断方法[J]. 高压电器, 2019, 55(08): 157-163.
- [17] 刘凯, 彭维捷, 杨学君. 特征优化和模糊理论在变压器故障诊断中的应用[J]. 电力系统保护与控制, 2016, 44(15): 54-60.
- [18] Dur V, Devarajan N, Soma D, et al. Neuro fuzzy schemes for fault detection in power transformer[J]. Applied Soft Computing Journal, 2007, 7(2): 534-539.



- [19] Nit M C, Ac A M, Nicola C I, et al. Power transformer fault diagnosis using fuzzy logic technique based on dissolved gas analysis and furan analysis[C]// International Conference on Optimization of Electrical & Electronic Equipment & Intl Aegean Conference on Electrical Machines & Power Electronics. IEEE, 2017.
- [20] 付刚, 王伟, 张洋, et al. 两种神经网络方法在电力变压器故障诊断中的性能分析[J]. 科技创新与应用, 2019(26).
- [21] 王峰, 毕建刚, 万梓聪, 等. 基于深度卷积神经网络的变压器故障诊断方法[J]. 广东电力, 2019, 32(09): 177-183.
- [22] 王阳, 乐健, 周谦, et al. 基于小波包分析与神经网络的变压器区内外故障判断方法[J/OL]. 电测与仪表: 1-10[2020-02-01].
- [23] Ill H A, Chai X R, Abu Bakar A H. Hybrid modified evolutionary particle swarm time varying acceleration coefficient-artificial neural network for power transformer fault diagnosis [J]. Measurement, 2016, 90: 94-102.
- [24] 曹先平, 邓黎明, 李振东, 等. 基于 DFTA 的变压器故障诊断专家系统研究[J]. 计算机时代, 2016(01): 5-8.
- [25] 徐阳, 谢天喜, 周志成, 等. 基于多维度信息融合的实用型变压器故障诊断专家系统[J]. 中国电力, 2017, 50(01): 85-91.
- [26] 张邵杰, 朱武. 基于 IFWA-PNN 的变压器故障诊断研究[J]. 科技创新与应用, 2022, 12(06): 86-88+91.
- [27] Velasquez, R.M.A. Lara, J.V.M. Expert system for power transformer diagnosis[C] // Proceedings of the 2017 IEEE 24th International Congress on Electronics, 2017.
- [28] 刘咏鑫, 宋斌, 王力农, 等. 基于混沌序列优化的 BP 网络油纸绝缘变压器寿命预测[J/OL]. 电测与仪表: 1-7[2021-04-11].
- [29] 黄新波, 蒋卫涛, 朱永灿, 等. 基于时间序列和支持向量机的变压器故障预测[J]. 高压技术, 2020, 46(07): 2530-2538.
- [30] 郑蕊蕊. 智能信息处理理论的电力变压器故障诊断方法[D]. 吉林: 吉林大学, 2010.
- [31] 刘慧鑫, 张江龙, 连鸿松, 等. 基于时间序列模型的变压器油中溶解气体预测[J]. 高压电器, 2019, 55(12): 193-199.
- [32] 陈伟根, 潘孙, 云玉新. 基于小波网络及油中溶解气体分析的电力变压器故障诊断方法[J]. 中国电机工程学报, 2008(7): 121-126.
- [33] 方健, 彭辉, 李自品. 改进小波网络在油浸式变压器故障诊断中的应用[J]. 高压电器, 2011(11): 115-120.
- [34] 王晶, 刘建新. 基于灰色新预测模式的变压器故障预测[J]. 华北电力大学学报(自然科学版): 10-14.
- [35] Wang G S, Liu Y, Chen X W, et al. Power transformer fault diagnosis system based on

- Internet of Things[J]. EURASIP Journal on Wireless Communications and Networking,2021,2021(1):68-77.
- [36] 黄新波, 马玉涛, 朱永灿.基于信息融合和 M-RVM 的变压器故障诊断方法[J]. 电力自动化设备, 2020, 40(12): 218-225.
- [37] 陈铁, 吕长钦, 张欣, 等.基于 KPCA-WPA-SVM 的变压器故障诊断模型[J]. 电测与仪表, 2021, 58(04): 158-164.
- [38] 薛建凯. 一种新型的群智能优化技术的研究与应用[D]. 上海: 东华大学, 2020.
- [39] 吕鑫, 慕晓冬, 张钧, 等. 混沌麻雀搜索优化算法[J]. 北京航空航天大学学报, 1-10.
- [40] 李黄曼, 张勇, 张瑶. 基于 ISSA 优化 SVM 的变压器故障诊断研究[J]. 电子测量与仪器学报, 2021, 35(03): 123-129.
- [41] 毛清华, 张强.融合柯西变异和反向学习的改进麻雀算法[J/OL]. 计算机科学与探索: 1-12[2021-04-12].
- [42] 冯帅. 基于反向学习策略的差分算法研究[D]. 北京: 北京邮电大学, 2021.
- [43] 李俊, 冯俊杰, 武文吉, 等. 基于改进萤火虫算法和多分类支持向量机的变压器故障诊断[J/OL]. 电测与仪表: 1-6[2021-04-11].
- [44] 郝玲玲, 朱永利.改进萤火虫算法与小波神经网络相结合的变压器故障诊断[J]. 科学技术与工程, 2019, 19(31): 156-161.
- [45] 方涛, 钱晔, 郭灿杰, 等. 基于天牛须搜索优化支持向量机的变压器故障诊断研究[J]. 电力系统保护与控制, 2020, 48(20): 90-96.
- [46] 郭林, 唐晶, 唐黎哲. 一种基于改进 BP 神经网络的变压器故障诊断方法[J]. 控制与信息技术, 2021(05): 209-219.
- [47] 万周立, 刘辉. 改进 GWO 优化 DBN 网络的变压器故障诊断研究[J]. 现代电子技术, 2021, 44(19): 1004-373.
- [48] 范晓丹, 付炜平, 赵智龙, 等. 基于长短时记忆网络油浸式变压器故障诊断研究[J]. 变压器, 2021, 58(09): 1001-1008.
- [49] 王建新, 陈伟根, 王品一, 等. 变压器故障特征气体空芯反谐振光纤增强拉曼光谱检测[J/OL]. 中国电机工程学报: 1-10[2021-12-02].
- [50] 赵玲玲, 王群京, 陈权, 等. 基于 IBBOA 优化 BP 神经网络的变压器故障诊断[J]. 电工电能新技术, 2021, 40(09): 39-46.
- [51] 肖怀硕, 李清泉, 施亚林, 等. 灰色理论-变分模态分解和 NSGA-II优化的支持向量机在变压器油中气体预测中的应用[J]. 中国电机工程学报, 2017, 37(12): 3643-3653+3694.
- [52] 周锋, 孙廷玺, 权少静, 等. 基于集合经验模态分解和极限学习机的变压器油中溶解气体体积分数预测方法[J]. 高电压技术, 2020, 46(10): 3658-3665.
- [53] 王春明, 朱永利. 基于 NSGA2 优化正则极限学习机的变压器油色谱故障诊断[J]. 高压

- 电器, 2020, 56(09): 210-215.
- [54] 吴杰康, 覃炜梅, 梁浩浩, 等. 基于自适应极限学习机的变压器故障识别方法[J]. 电力自动化设备, 2019, 39(10): 181-186.
- [55] Xu Z C, Yong L Z, Fei P. Prediction Research of Transformer Fault Based on Regular Extreme Learning Machine[J].Advanced Materials Research,2014,3593:332-345
- [56] 吕艳硕, 张东亮, 毕影娇, 等. 基于改进核极限学习机的变压器故障诊断[J]. 电气时代, 2021(11): 56-60.
- [57] 何宁辉, 丁培, 马飞越. 基于优化极限学习机的变压器故障诊断方法研究[J]. 电子器件, 2021, 44(04): 897-902.

## 在学研究成果

### 一、科研项目

参与国家自然科学基金资助项目（51675350），“基于结构噪声信息的大型风力机传动系统运行状态识别与故障诊断方法研究”，（2017 年～2020 年），已结题。

参与宁波坤博测控科技有限公司“林德气体气膨增压段离心泵故障诊断项目”，（2020～2021），核心研究人员，已完成。

## 致谢

三年时间，如白驹过隙转瞬即逝，依稀记得初入学校时的满眼新奇，内心更是充满了无尽的喜悦与对未来的无限憧憬。曾经书生意气的我，如今脸上多了一些成熟与沉稳，面对即将到来的社会生活，内心依然充满了希望。回首往昔，三年间，有过迷茫、有过昂扬、有过无措、有过无畏，不知不觉之间，它们让我的研究生生活充满了青春的味道，五彩斑斓却又真实平淡。

很幸运我能加入到“振动工程家族”这个大家族，其中我要重点感谢我的研究生导师。所谓：传道授业解惑也，他无不面面俱到。极具深度的文化学习，极具广度的知识范畴，都让我在三年的学习中得到了快速的成长。他亲历亲为的治学态度，他事无巨细的科研精神，无不激励着我努力向前。陈老师以身作则，用自己的行动和思想影响着我，让我在求学的路上倍感温馨。

百善孝为先。依然记得入学前，父亲对我的谆谆教诲，母亲对我的拳拳心语。都说世间最无私的爱就是父母对子女的爱。研究生三年让我深刻的体会到了这一点，在这三年的学习过程中，渐渐的明白了父母的艰辛，见证了他们渐白的鬓角，深刻体会到了他们在背后的默默付出。正是他们这种付出激励着我更加认真刻苦的完成三年的硕士生涯。

感谢宁波坤博测控科技有限公司的孙总经理以及各位同事。可以说在这八个月的实习期间，真正体会到了社会和校园的差距。正是在你们的帮助之下，让我能够更好的将书本上的理论知识应用于实际的生产生活之中。通过一次次认真的工作，让我可以迅速地积累经验，避免以后步入社会变得手足无措；感谢同届课题组的所有同学，在研究生求学期间一起讨论课题，一起外出实习，共同成长，共同进步，在论文完成的过程中给我提出了诸多宝贵的意见。这不仅提高了我的知识水平，更加增加了我的学术视野。

人生总是重复着结束和开始，三年的研究生旅程结束了，另一段旅程即将开始。前路坎坷，但我依然信心十足；在未来前进的路上，我必将秉承“自强 笃行”的校训理念，将工大精神发扬光大。

最后，衷心祝愿各位评审老师、专家及教授，万事胜意！